Приближённое решение двумерной задачи рассеяния на основе POD и нейросетевого отображения коэффициентов

Аннотация. Исследуется приближённое отображение от коэффициентов среды и параметров плоской волны к комплексному рассеянному полю на фиксированной конечно-элементной сетке. Различаются три задачи: предсказание для новых сред, интерполяция по частоте при фиксированном материале и перенос за пределы обученной полосы. Для архивного эксперимента на 1000 средах с полным SVD достаточно 71 моды на каждую часть поля, чтобы средняя валидационная узловая ошибка проекции была меньше 1%. Сохранённый запуск сети после 500 эпох даёт среднюю тестовую FEM-ошибку L^2 6,455%; его обучение повторно не выполнялось. Для одной фиксированной среды randomized SVD-SNO достигает 0,961% при $k \in [1, 2]$ и 5,538% при отдельном обучении на $k \in [4, 8]$. Замороженная низкочастотная модель в высокой полосе даёт 144,178%. При уточнении сетки высокочастотные FEM-метки меняются на 13–14%, что ограничивает выводы о физической точности. Сохранены также неуспешные результаты пилотного сопоставления SVD-SNO, Chebyshev-SNO и FNO на новых средах. Для каждой серии указаны свой протокол разбиения, происхождение чисел и пределы воспроизводимости.

Ключевые слова: уравнение Гельмгольца; рассеяние волн; метод конечных элементов; POD; спектральный нейрооператор; FNO; полиномы Чебышёва.

1. ВВЕДЕНИЕ

Серия расчётов рассеяния состоит из задач с одинаковой внешней областью, но различными материалами, частотами или направлениями волны. Прямое решение каждой задачи даёт контроль над дискретной постановкой, однако повторяет сборку и решение системы. Альтернативный путь — заранее получить выборку FEM-полей и обучить отображение от параметров к полю. В FNO обучаемая часть действует на пространственные признаки через преобразование Фурье [1]; в SNO вход и выход задаются коэффициентами рядов [2].

Здесь пространственные функции выбираются по конечно-элементным снимкам посредством сингулярного разложения (SVD). Усечённое разложение даёт POD-представление (proper orthogonal decomposition), а сеть предсказывает его коэффициенты. Использование фиксированных POD-мод для выхода известно, в частности, из POD-DeepONet [3]. Рассматриваемая ниже сеть имеет собственную формулу смешивания коэффициентов; это не воспроизведение POD-DeepONet или всех архитектур SNO. Проверяется конкретная адаптация к дискретной задаче рассеяния.

Цель работы — установить, какую часть ошибки задаёт выбранное пространство представления и какую добавляет обучаемое отображение. Сеть с POD-базисами далее обозначается SVD-SNO. Рассматриваются фиксированные 24 допустимых положения включений; перенос на произвольную геометрию из этого построения не следует. Сначала разбирается архивный запуск на 1000 разных средах. Затем на воспроизводимых примерах сравниваются фиксированный материал и новые среды, а также обучение внутри полосы и частотная экстраполяция. Разные серии не объединяются в одну оценку точности.

2. ПОСТАНОВКА ЗАДАЧИ И ДИСКРЕТИЗАЦИЯ

Пусть $\Omega = (-2, 2)^2 \subset \mathbb{R}^2$. Падающая плоская волна имеет вид

$$u_i(\boldsymbol{x}) = \exp(\mathrm{i}k\boldsymbol{d} \cdot \boldsymbol{x}), \qquad \boldsymbol{d} = (\cos\theta, \sin\theta), \quad k > 0. \tag{1}$$

Коэффициенты $A(\boldsymbol{x}) > 0$ и $n(\boldsymbol{x}) > 0$ — вещественные скалярные кусочно-постоянные функции. Вне включений они равны единице. Полное поле $u = u_i + u_s$ удовлетворяет уравнению $\nabla \cdot (A\nabla u) + k^2 n u = 0$. Поэтому для рассеянного поля получаем

$$\nabla \cdot (A\nabla u_s) + k^2 n u_s = \nabla \cdot \big((1 - A)\nabla u_i\big) + k^2(1 - n)u_i, \quad \boldsymbol{x} \in \Omega. \tag{2}$$

При разрывных коэффициентах равенство (2) понимается в слабом смысле. Это учитывает вклад границ раздела материалов; замена его правой части только объёмным выражением внутри каждого материала не была бы эквивалентной постановкой.

На внешней границе задаётся локальное поглощающее условие первого порядка

$$A\,\partial_\nu u_s - \mathrm{i}k u_s = 0, \qquad \boldsymbol{x} \in \partial\Omega, \tag{3}$$

где ν — внешняя единичная нормаль. Все включения расположены строго внутри области; в окрестности $\partial\Omega$ имеем $A = n = 1$. Условие (3) приближает излучение на конечной границе. Ниже оценивается приближение решения этой ограниченной задачи; погрешность замены внешней задачи отдельно не исследуется.

Каждая среда получается активацией от 3 до 10 кругов из фиксированного набора $D_1, \ldots, D_{24}$, показанного на рис. 1. Внутри каждого активного круга независимо выбираются значения

$$0{,}6 \leqslant A_j \leqslant 0{,}9, \qquad 1{,}5 \leqslant n_j \leqslant 3, \qquad 1 \leqslant k \leqslant 2. \tag{4}$$

Материальные коэффициенты имеют логарифмически равномерные распределения в указанных диапазонах. Число активных кругов выбирается равновероятно из целых чисел от 3 до 10, а набор кругов — без повторений. Волновое число выбирается равномерно для каждой среды и сохраняется при смене направления падающей волны.

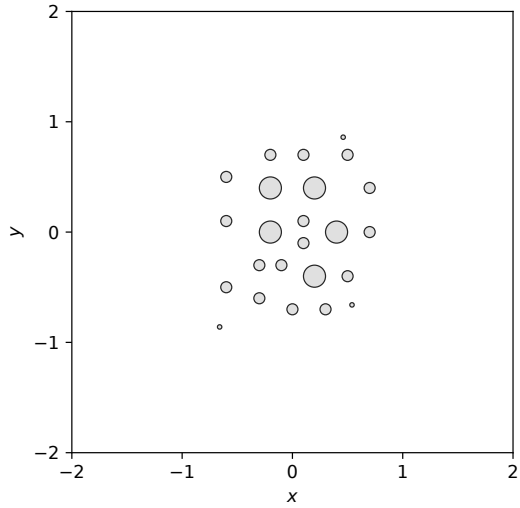


Рис. 1: Расчётная область и 24 допустимых круговых включения. В отдельной среде активны от 3 до 10 кругов; остальные заполнены фоновым материалом.

Общая неструктурированная треугольная сетка согласована с границами всех допустимых кругов. Коэффициенты среды задаются поэлементно. Пусть $V_h \subset H^1(\Omega;\mathbb{C})$ — пространство непрерывных кусочно-линейных функций. С учётом (3) слабая задача имеет вид: найти $u_{s,h} \in V_h$, такое, что для любого $v_h \in V_h$

$$\begin{aligned} \int_\Omega A\nabla u_{s,h}\cdot\nabla\overline{v_h}\,d\boldsymbol{x} - k^2\int_\Omega n u_{s,h}\overline{v_h}\,d\boldsymbol{x} - \mathrm{i}k\int_{\partial\Omega} u_{s,h}\overline{v_h}\,ds \\ = -\int_\Omega (A-1)\nabla u_i\cdot\nabla\overline{v_h}\,d\boldsymbol{x} + k^2\int_\Omega (n-1)u_i\overline{v_h}\,d\boldsymbol{x}. \end{aligned} \tag{5}$$

Знаки правой части следуют из интегрирования (2) по частям; граничный член от контраста коэффициентов равен нулю. Дискретная система имеет вид

$$\big(K(A) - k^2 M(n) - \mathrm{i}k M_{\partial\Omega}\big)\boldsymbol{u}_s = \boldsymbol{b}(A, n, k, \theta) \tag{6}$$

и решается прямым методом LU. Здесь $K(A)$, $M(n)$ и $M_{\partial\Omega}$ — матрицы жёсткости, взвешенной массы и граничной массы соответственно.

Целевой фоновый шаг сетки равен 4/96; сетка содержит $N_h = 11\,380$ узлов и 22 374 треугольника. Для нейросетевого представления значения A и n усредняются в каждом узле по прилегающим элементам с одинаковыми весами. Конечно-элементные решения вычисляются с исходными поэлементными коэффициентами, поэтому это усреднение влияет только на входное представление модели.

3. POD-ПРЕДСТАВЛЕНИЕ И ВЫБОР РАНГА

3.1. Как сингулярное разложение выделяет пространственные моды

Пусть $\boldsymbol{f}^{(s)} \in \mathbb{R}^{N_h}$, $s = 1, \ldots, N_f$, — обучающие снимки одного вещественного поля. Определим среднее и матрицу центрированных снимков:

$$\boldsymbol{m}_f = \frac{1}{N_f} \sum_{s=1}^{N_f} \boldsymbol{f}^{(s)}, \qquad F_c = \begin{bmatrix} (\boldsymbol{f}^{(1)} - \boldsymbol{m}_f)^{\mathsf{T}} \\ \vdots \\ (\boldsymbol{f}^{(N_f)} - \boldsymbol{m}_f)^{\mathsf{T}} \end{bmatrix} = U \Sigma V^{\mathsf{T}}. \tag{7}$$

Пусть $p = \min(N_f, N_h)$. В экономном разложении $U \in \mathbb{R}^{N_f \times p}$, $V \in \mathbb{R}^{N_h \times p}$, а $\Sigma = \operatorname{diag}(\sigma_1, \ldots, \sigma_p)$, где $\sigma_1 \geqslant \cdots \geqslant \sigma_p \geqslant 0$. Столбец $\boldsymbol{v}_j$ матрицы V задаёт пространственный рисунок на узлах сетки; столбец $\boldsymbol{u}_j$ матрицы U показывает, с какими весами этот рисунок входит в разные снимки. Таким образом,

$$F_c = \sum_{j=1}^{p} \sigma_j \boldsymbol{u}_j \boldsymbol{v}_j^{\mathsf{T}}, \qquad \boldsymbol{f}^{(s)} = \boldsymbol{m}_f + \sum_{j=1}^{p} \sigma_j U_{sj} \boldsymbol{v}_j. \tag{8}$$

Сингулярное значение измеряет вклад моды в суммарную квадратичную изменчивость обучающих снимков. POD оставляет ведущие пространственные рисунки и заменяет узловой вектор коротким вектором их весов. Это линейное сжатие данных; сама по себе процедура SVD не предсказывает решение по параметрам среды.

В основном эксперименте используется полный экономный SVD с последующим усечением. Первые r правых сингулярных векторов образуют матрицу $\Phi_{f,r} \in \mathbb{R}^{N_h \times r}$, для которой $\Phi_{f,r}^{\mathsf{T}} \Phi_{f,r} = I_r$. Кодирование и восстановление задаются формулами

$$\boldsymbol{c}_f = \Phi_{f,r}^{\mathsf{T}} (\boldsymbol{f} - \boldsymbol{m}_f), \qquad \boldsymbol{f}_r = \boldsymbol{m}_f + \Phi_{f,r} \boldsymbol{c}_f. \tag{9}$$

Для обучающей матрицы коэффициентов $C_f = F_c \Phi_{f,r} = U_r \Sigma_r$. Усечённое SVD оптимально приближает центрированную обучающую матрицу в норме Фробениуса; это свойство не гарантирует точность на новых средах или оптимальность в другой норме. Доля сохранённой квадратичной изменчивости и остаток обучающей матрицы равны

$$E_r = \frac{\sum_{j=1}^{r} \sigma_j^2}{\sum_{j=1}^{p} \sigma_j^2}, \qquad \|F_c - U_r \Sigma_r V_r^{\mathsf{T}}\|_F^2 = \sum_{j=r+1}^{p} \sigma_j^2. \tag{10}$$

Здесь E_r определено при ненулевой центрированной матрице. Высокое значение E_r служит диагностикой сжатия обучающих данных; в работе ранг выбирается непосредственно по ошибке восстановления валидационных полей.

3.2. Отдельные базисы и валидационный выбор ранга

Отдельные базисы строятся для A, n, $\operatorname{Re} u_s$ и $\operatorname{Im} u_s$. Для коэффициентов среды берётся по одному снимку на обучающую среду, для решения — все её направления. Средние поля и базисы вычисляются только по обучающей выборке.

Далее $\boldsymbol{u}^{(s)} \in \mathbb{C}^{N_h}$ обозначает узловой вектор рассеянного поля. При одинаковом числе r мод для обеих частей его проекция равна

$$\boldsymbol{u}_r^{(s)} = \boldsymbol{m}_{\mathrm{re}} + \Phi_{\mathrm{re},r}\boldsymbol{c}_{\mathrm{re}}^{(s)} + \mathrm{i}\big(\boldsymbol{m}_{\mathrm{im}} + \Phi_{\mathrm{im},r}\boldsymbol{c}_{\mathrm{im}}^{(s)}\big). \tag{11}$$

Общий ранг решения выбирается по валидационной выборке из предварительно вычисленных первых 136 мод:

$$R = \min\left\{ r \in \{1,\dots,136\} : \quad \frac{1}{N_{\mathrm{val}}} \sum_{s\in\mathcal{I}_{\mathrm{val}}} \frac{\|\boldsymbol{u}^{(s)} - \boldsymbol{u}_r^{(s)}\|_2}{\|\boldsymbol{u}^{(s)}\|_2} \leqslant \varepsilon_{\mathrm{POD}} \right\}. \tag{12}$$

Для $\varepsilon_{\mathrm{POD}} = 10^{-2}$ получено $R = 71$. Средняя валидационная узловая ошибка проекции составляет 0,9696%, 95-й процентиль — 2,3105%. Таким образом, допуск относится к средней ошибке, а не к каждому полю. Тестовые ошибки не входят в критерий (12).

При фиксированных кругах поэлементные поля имеют вид

$$A = 1 + \sum_{j=1}^{24} a_j \chi_{D_j}, \qquad n = 1 + \sum_{j=1}^{24} b_j \chi_{D_j},$$

где $a_j = b_j = 0$ для неактивного включения. Усреднение по узлам является линейным, поэтому размерность пространства центрированных входных снимков не превышает 24. В расчёте оба входных численных ранга равны 24. Компоненты, для которых сингулярное значение не превышает 10^{-5} от наибольшего значения соответствующего входного поля, зануляются.

Для каждой компоненты применяется нормировка

$$\widetilde{c}_{f,j} = (c_{f,j} - \mu_{f,j})/s_{f,j}, \qquad \widetilde{k} = (k - \mu_k)/s_k, \tag{13}$$

где средние и масштабы оцениваются по обучающей выборке. Обозначим исходное стандартное отклонение модальных коэффициентов через $\sigma_{f,j}$. Масштаб $s_{f,j}$ равен $\sigma_{f,j}$, если оно превышает $\max(10^{-6}\max_j \sigma_{f,j}, 10^{-12})$; иначе используется единица. Это исключает усиление численного шума в неактивных входных компонентах. При нормировке k к стандартному отклонению добавляется 10^{-8}.

3.3. Чем рандомизированный SVD отличается от полного

Полный экономный SVD раскладывает всю матрицу F_c, после чего сохраняются нужные столбцы. Рандомизированный вариант [5] сначала приближённо находит её ведущее подпространство. Для требуемого числа r_0 мод генерируется случайная матрица $\Omega \in \mathbb{R}^{N_h\times(r_0+p_0)}$, где p_0 — число дополнительных векторов. Затем вычисляются

$$Y = F_c\Omega, \quad Q = \operatorname{orth}(Y), \quad H = Q^{\mathsf{T}}F_c = \widetilde{U}\widetilde{\Sigma}\widetilde{V}^{\mathsf{T}}. \tag{14}$$

Первые r_0 столбцов $\widetilde{V}$ используются как приближённые пространственные моды. При степенных итерациях образ Y уточняется умножениями на F_c^{T} и F_c с промежуточной QR-ортогонализацией; это усиливает вклад ведущих сингулярных направлений. В сохранённой диагностике $r_0 = 136$, $p_0 = 10$, выполнены две такие итерации. Оба варианта меняют способ построения POD-базиса, но не принцип дальнейшего нейросетевого предсказания коэффициентов. Основные результаты ниже относятся к полному SVD.

4. НЕЙРОСЕТЕВОЕ ОТОБРАЖЕНИЕ КОЭФФИЦИЕНТОВ

4.1. Роль SNO в вычислительной цепочке

Приближается отображение $(A, n, \theta, k) \mapsto u_s$. В SVD-SNO оно разбито на три этапа: кодирование полей среды в POD-коэффициенты, обучаемое нелинейное отображение коэффициентов и декодирование выходных коэффициентов в поле. Базисы фиксируются до обучения сети. При новом запросе истинные коэффициенты решения неизвестны: именно их предсказывает сеть по входным данным. FEM-решатель нужен для создания обучающих меток, а не для вычисления каждого нового предсказания.

Название SNO связано с работой [2], где отображение строится между коэффициентами рядов Фурье или Чебышёва и нелинейности применяются в пространстве коэффициентов. Здесь вместо заранее заданных рядов используются POD-моды, найденные по данным. Их номер упорядочен по сингулярным значениям и не является волновым числом Фурье. Поэтому свойства исходного SNO нельзя автоматически переносить на данную модель.

4.2. Архитектура исследованной сети

Формулы этого подраздела описывают JAX-реализацию сохранённого эксперимента, для которого далее приведены численные результаты. Для каждого $j = 1, \ldots, R$ формируется строка входной матрицы $X \in \mathbb{R}^{R\times 5}$:

$$X_{j,:} = \left(\widetilde{c}_{A,j}, \widetilde{c}_{n,j}, \cos\theta, \sin\theta, \widetilde{k}\right). \tag{15}$$

Входные векторы коэффициентов длины 24 дополняются нулями до $R = 71$. Параметры волны повторяются в каждой строке. Индекс j обозначает номер POD-моды соответствующего поля; моды разных полей построены независимо.

Чтобы читать формулу блока, следует различать передаваемые данные и обучаемые параметры. Матрица $Z^{(\ell)}$ — скрытое состояние для *одного* входного примера после ℓ-го блока. Верхний индекс обозначает номер слоя, а не степень. Строка j соответствует позиции моды, столбец c — скрытому каналу признаков. Например, $Z^{(\ell)}_{j,c}$ является одним числом, вычисленным сетью для текущей среды и волны. Сами скрытые каналы не отождествляются с A, n, Re или Im: их представление формируется при обучении.

Матрицы $B^{(\ell)}$ и $W^{(\ell)}$, напротив, являются весами сети: они изменяются оптимизатором на этапе обучения и фиксируются при предсказании. Для разных слоёв используются разные веса; для всех примеров в одном слое — одни и те же. Их назначение суммировано в табл. 1.

Таблица 1: Данные и параметры исторической SVD-SNO при $R = 71$, ширине $w = 64$

Обозначение	Размер	Смысл
$Z^{(\ell)}$	71×64	Скрытые признаки; вычисляются заново для каждого запроса.
$B^{(\ell)}$	71×71	Обучаемые веса обмена между строками, то есть позициями мод.
$W^{(\ell)}_{\mathrm{loc}}$, $W^{(\ell)}_{\mathrm{ch}}$	64×64	Обучаемые веса смешивания скрытых каналов.
$\Phi_{f,R}$	$N_h \times 71$	Пространственные POD-моды; найдены по снимкам до обучения сети.

Таким образом, B не является POD-базисом: базис обозначается через Φ и связывает коэффициенты с физическими узлами. Также B не является матрицей конечных элементов. Для пакета примеров к Z добавляется первая ось пакета, то есть в коде хранится массив

$[N_{\text{batch}}, R, w]$; далее эта ось опущена, поскольку одинаковые операции выполняются независимо для каждого примера.

Начальное преобразование и четыре остаточных блока имеют вид

$$\begin{aligned} Z^{(0)} &= \sigma\big(XW_0 + \mathbf{1}b_0^{\mathsf{T}}\big), \\ Z^{(\ell+1)} &= Z^{(\ell)} + \sigma\big(Z^{(\ell)}W_{\text{loc}}^{(\ell)} + \mathbf{1}(b_{\text{loc}}^{(\ell)})^{\mathsf{T}} \\ &\qquad + B^{(\ell)}Z^{(\ell)}W_{\text{ch}}^{(\ell)} + \mathbf{1}(b_{\text{ch}}^{(\ell)})^{\mathsf{T}}\big), \quad \ell = 0, \dots, 3, \end{aligned} \tag{16}$$

где σ — GELU, $Z^{(\ell)} \in \mathbb{R}^{R\times 64}$, $B^{(\ell)} \in \mathbb{R}^{R\times R}$, $W_{\text{loc}}^{(\ell)}, W_{\text{ch}}^{(\ell)} \in \mathbb{R}^{64\times 64}$. Вектор $\mathbf{1} \in \mathbb{R}^R$ обеспечивает одинаковый сдвиг во всех строках. Матрица $B^{(\ell)}$ смешивает моды, а матрицы $W^{(\ell)}$ — каналы. Выходная линейная проекция

$$\widehat{\widetilde{C}} = Z^{(4)}W_{\text{out}} + \mathbf{1}b_{\text{out}}^{\mathsf{T}} \in \mathbb{R}^{R\times 2}$$

даёт нормированные коэффициенты действительной и мнимой частей. При указанных размерах сеть содержит 53 958 обучаемых вещественных параметров.

Направления смешивания можно проверить по отдельным элементам:

$$(ZW)_{j,c} = \sum_{d=1}^{w} Z_{j,d}W_{d,c}, \qquad (BZ)_{j,c} = \sum_{i=1}^{R} B_{j,i}Z_{i,c}. \tag{17}$$

Умножение *справа* на W смешивает столбцы одной строки: признаки различных каналов одной модальной позиции. Умножение *слева* на B смешивает строки одного столбца: признаки одного канала из разных модальных позиций. Форма массива $R \times w$ при этих операциях сохраняется. Числовой пример на рис. 2 использует $R = 3$, $w = 2$ только для наглядности; это не размеры обученной сети. Векторы b в формуле блока являются обучаемыми сдвигами, одинаково добавляемыми ко всем строкам.

Входное преобразование увеличивает число каналов с 5 до 64, чтобы сеть могла хранить несколько скрытых признаков для каждой моды. Локальная ветвь ZW_{loc} преобразует каналы одной строки без обмена между модами; произведение BZW_{ch} обеспечивает обмен между всеми строками и каналами. Здесь слово «локальная» относится к номеру моды, а не к точке физической области. Нелинейность GELU позволяет описывать нелинейную зависимость решения от среды, а остаточное сложение сохраняет вход блока и обучает его поправку. Последняя проекция $64 \to 2$ выдаёт два вещественных коэффициента для каждой выходной моды. Дополнительные пространственные координаты в сеть этой реализации не подаются: геометрия узлов содержится в сохранённых базисах.

Число параметров можно проверить непосредственно по размерам матриц: входное преобразование содержит $5 \cdot 64 + 64 = 384$ параметра; каждый блок — $71^2 + 2(64^2 + 64) = 13\,361$; выходная проекция — $64 \cdot 2 + 2 = 130$. Всего $384 + 4 \cdot 13\,361 + 130 = 53\,958$.

После обратной нормировки восстанавливается поле

$$\widehat{\boldsymbol{u}} = \boldsymbol{m}_{\text{re}} + \Phi_{\text{re},R}\widehat{\boldsymbol{c}}_{\text{re}} + \mathrm{i}\big(\boldsymbol{m}_{\text{im}} + \Phi_{\text{im},R}\widehat{\boldsymbol{c}}_{\text{im}}\big). \tag{18}$$

Для нового запроса используются сохранённые средние, базисы, нормировки и веса сети. При измерении стоимости предсказания необходимо учитывать кодирование входа и реконструкцию (18).



Рис. 2: Как читать Z, W и B. Строки Z — позиции мод, столбцы — скрытые каналы; Z зависит от входного примера. Обучаемая матрица W смешивает каналы, а B — модальные позиции. На условных числах отдельно показаны операции ZW и BZ, ниже — порядок обработки PyTorch-блока legacy. Это арифметическая иллюстрация, а не результаты обучения.

4.3. Результат: действительная часть, мнимая часть и модуль

Искомое поле является комплексным. Для SNO и FNO единый физический результат представляется тремя вещественными полями:

$$\begin{aligned} \widehat{u}_{\mathrm{re}}(\boldsymbol{x}) &= \mathrm{Re}\,\widehat{u}_s(\boldsymbol{x}), \\ \widehat{u}_{\mathrm{im}}(\boldsymbol{x}) &= \mathrm{Im}\,\widehat{u}_s(\boldsymbol{x}), \\ \widehat{u}_{\mathrm{abs}}(\boldsymbol{x}) &= |\widehat{u}_s(\boldsymbol{x})| = \sqrt{\widehat{u}_{\mathrm{re}}(\boldsymbol{x})^2 + \widehat{u}_{\mathrm{im}}(\boldsymbol{x})^2}. \end{aligned} \tag{19}$$

Здесь $u_s \equiv u_{\mathrm{scattering}}$; во всех трёх случаях рассматривается рассеянное поле. В SVD-SNO первые два поля восстанавливаются по формуле (18). Модуль вычисляется после обратной нормировки и пространственной реконструкции; модуль модальных коэффициентов не даёт модуль поля. Отдельный независимый выход сети для модуля не требуется, поскольку третье поле однозначно определяется первыми двумя. Поэтому сохраняются два обучаемых выходных канала и согласованность трёх представлений.

При визуальном сравнении для каждого представления следует показывать FEM-поле, предсказание и абсолютную ошибку соответствующего поля. При этом $\big||\widehat{u}_s| - |u_s|\big|$ характеризует ошибку амплитуды и отличается от комплексной ошибки $|\widehat{u}_s - u_s|$, учитывающей также фазу. Числа в таблице результатов ниже относятся к комплексному полю, а не к отдельно измеренным ошибкам трёх изображений.

4.4. Сохранённая PyTorch-архитектура и отличие от FNO

Сохранённые PyTorch-модели статической и пилотной серий используют другой блок SVD-SNO. Независимые коэффициенты A и n и три параметра волны объединяются в один вектор; общий линейный слой переводит его в массив размера $R \times w$. Затем каждый остаточный блок последовательно смешивает каналы и моды, после чего применяет GELU и добавляет вход блока. При тех же направлениях умножения это записывается как

$$Z^{(\ell+1)} = Z^{(\ell)} + \sigma\Big(B^{(\ell)}\big(Z^{(\ell)}W^{(\ell)} + \mathbf{1}(b^{(\ell)})^{\mathsf{T}}\big)\Big). \tag{20}$$

Сдвиг здесь добавляется *до* смешивания мод. Отдельной локальной ветви из (16) у этого варианта нет; начальное преобразование также не содержит GELU. Проекция в два канала и POD-декодирование сохраняются. Далее эта версия называется *legacy*; её обученные состояния не переинтерпретируются как результаты новой архитектуры. Поэтому число 53 958 и ошибки основного эксперимента относятся к JAX-запуску, а числа статических таблиц — к сохранённой PyTorch-версии (20).

Для новых обучений в коде выделена версия 2 с помодовым входом, начальной GELU и отдельной локальной ветвью:

$$Z^{(\ell+1)} = Z^{(\ell)} + \sigma\Big(Z^{(\ell)}W_{\mathrm{loc}}^{(\ell)} + \mathbf{1}(b_{\mathrm{loc}}^{(\ell)})^{\mathsf{T}} + B^{(\ell)}Z^{(\ell)}W_{\mathrm{ch}}^{(\ell)}\Big). \tag{21}$$

Число позиций равно $\max(r_A, r_n, r_{\mathrm{out}})$; выход берётся по первым r_{out} позициям. Наличие одинакового индекса не отождествляет независимые входные и выходные POD-базисы. Версия сохраняется вместе с весами. Архивные и статические legacy-результаты ниже сохраняют прежнюю версию; новый запуск версии 2 обозначен отдельно.

В FNO [1] скрытые признаки хранятся на регулярной пространственной сетке. Спектральная ветвь блока выполняет FFT, умножает сохранённые низкочастотные коэффициенты на обучаемые матрицы и возвращает результат обратным FFT. В текущей реализации эта ветвь суммируется с преобразованием каналов в каждой точке, затем применяются GELU и остаточное сложение. Таким образом, FNO возвращается в физическое пространство внутри каждого блока, а SVD-SNO смешивает POD-коэффициенты и декодирует поле в конце. Выход

FNO также содержит два вещественных канала; после декодирования на FEM-узлы модуль вычисляется по (19). Результаты FNO не входят в таблицу исторического JAX-эксперимента 4.

На рис. 4 показана текущая конфигурация FNO для статических наборов: сетка 32×32, семь каналов, ширина 24, три блока и нулевое дополнение справа и снизу на восемь точек. Вход содержит нормированные A, n, k, $\cos\theta, \sin\theta$ и координаты из $[-1, 1]$. После удаления дополнения и проекции в два канала выполняется билинейная интерполяция в FEM-узлы, затем обратная нормировка. Постоянство материала не удаляет каналы A, n из FNO.

На рис. 3 показан путь от данных до рассеянного поля. Две панели разделяют сохранённый JAX-эксперимент и PyTorch-версию legacy; общие названия этапов не означают совпадения блоков или обученных весов. На схеме q — общий входной вектор длины $d = r_A + r_n + 3$, $H = w$ — ширина скрытого слоя, L — число остаточных блоков.

4.5. Chebyshev-SNO: фиксированный базис вместо POD

Chebyshev-SNO сохраняет предсказание в пространстве коэффициентов, но использует тензорные полиномы, заданные до получения данных [2]. При $\xi = x/2$, $\eta = y/2$ пространственные функции имеют вид

$$\psi_{ab}(x, y) = T_a(\xi) T_b(\eta), \qquad T_a(\cos t) = \cos(at). \tag{22}$$

На каждой оси берутся $m = 32$ узла Лобатто в возрастающем порядке, $\xi_j = \cos(\pi(1 - j/(m - 1)))$, $j = 0, \ldots, m - 1$. Обозначим $S_{ja} = T_a(\xi_j)$ и положим $d_0 = d_{m-1} = 1/2$, $d_j = 1$ для остальных индексов. Используемый DCT-I задаётся матрицей

$$\mathcal{A}_{aj} = \frac{2}{m-1} d_a S_{ja} d_j, \qquad C = \mathcal{A} F \mathcal{A}^{\mathsf{T}}, \qquad F = S C S^{\mathsf{T}}. \tag{23}$$

Последнее равенство точно восстанавливает значения на узлах при сохранении всех m мод по каждой оси. Для $m = 3$ значения полинома T_2 в узлах $(-1, 0, 1)$ равны $(1, -1, 1)$, а его коэффициенты в принятой нормировке — $(0, 0, 1)$. Этот простой пример фиксирует коэффициенты на концах и исключает неявные множители $1/2$ в записи ряда.

В пилоте оставляются первые 8×8 мод каждого из семи каналов: $A, n, k, \cos\theta, \sin\theta, \xi, \eta$. Линейный подъём даёт массив $8 \times 8 \times 24$. Три блока legacy смешивают каналы и последовательно обе модальные оси, затем применяют GELU и остаточное сложение. Линейная проекция выдаёт два канала коэффициентов, обратное преобразование восстанавливает Re и Im. Число параметров равно

$$(7 \cdot 24 + 24) + 3\big(24^2 + 24 + 2 \cdot 8^2\big) + (24 \cdot 2 + 2) = 2426.$$

FEM-поля предварительно переносятся на тензорные узлы по барицентрическим весам исходных треугольников. Обратный перенос в FEM-узлы использует билинейную интерполяцию. Поэтому DCT-I не применяется к произвольному порядку FEM-узлов. Ошибки переноса и усечения сохраняются даже при точном преобразовании (23). В отличие от POD, порядок полиномов не адаптируется к материалу; в отличие от FNO, GELU действует на коэффициенты, а не на значения поля между преобразованиями. Эти различия задают проверяемые варианты модели, но не предопределяют их точность.

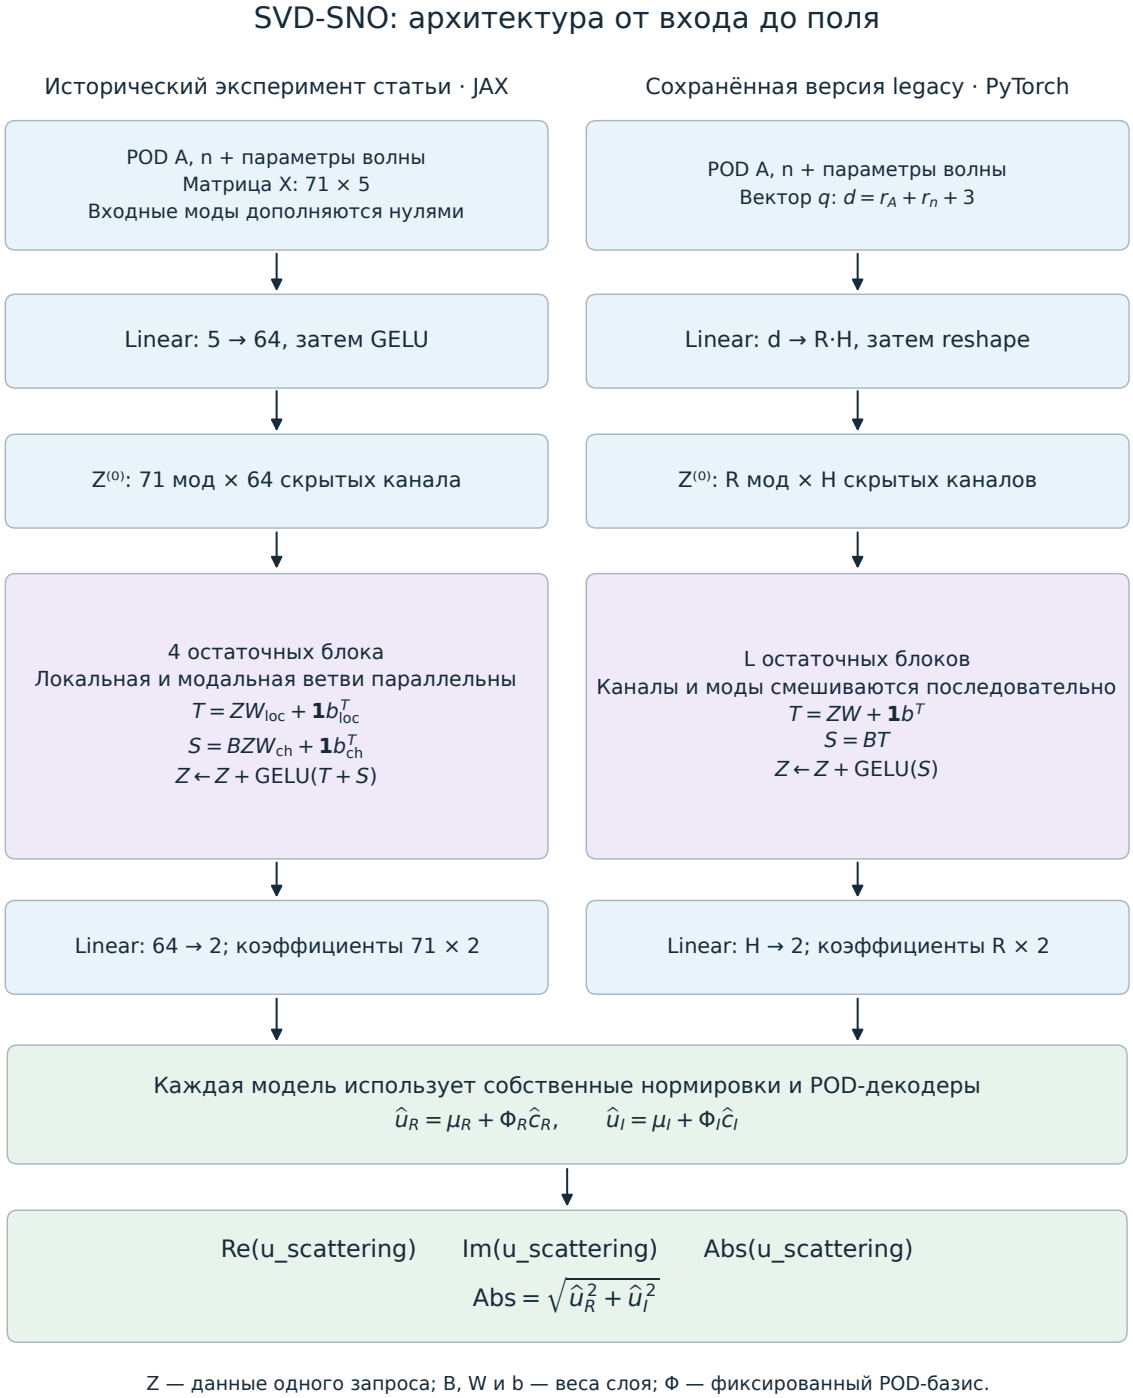


Рис. 3: Сохранённые архитектуры SVD-SNO. Слева: историческая JAX-сеть с входом $R \times 5$, начальной GELU и четырьмя блоками с двумя ветвями. Справа: PyTorch legacy с единым входным вектором и последовательным смешиванием каналов и мод. В обоих случаях предсказываются коэффициенты Re и Im, затем поле восстанавливается и вычисляется Abs. Исторические результаты относятся к левой панели, статические — к правой.

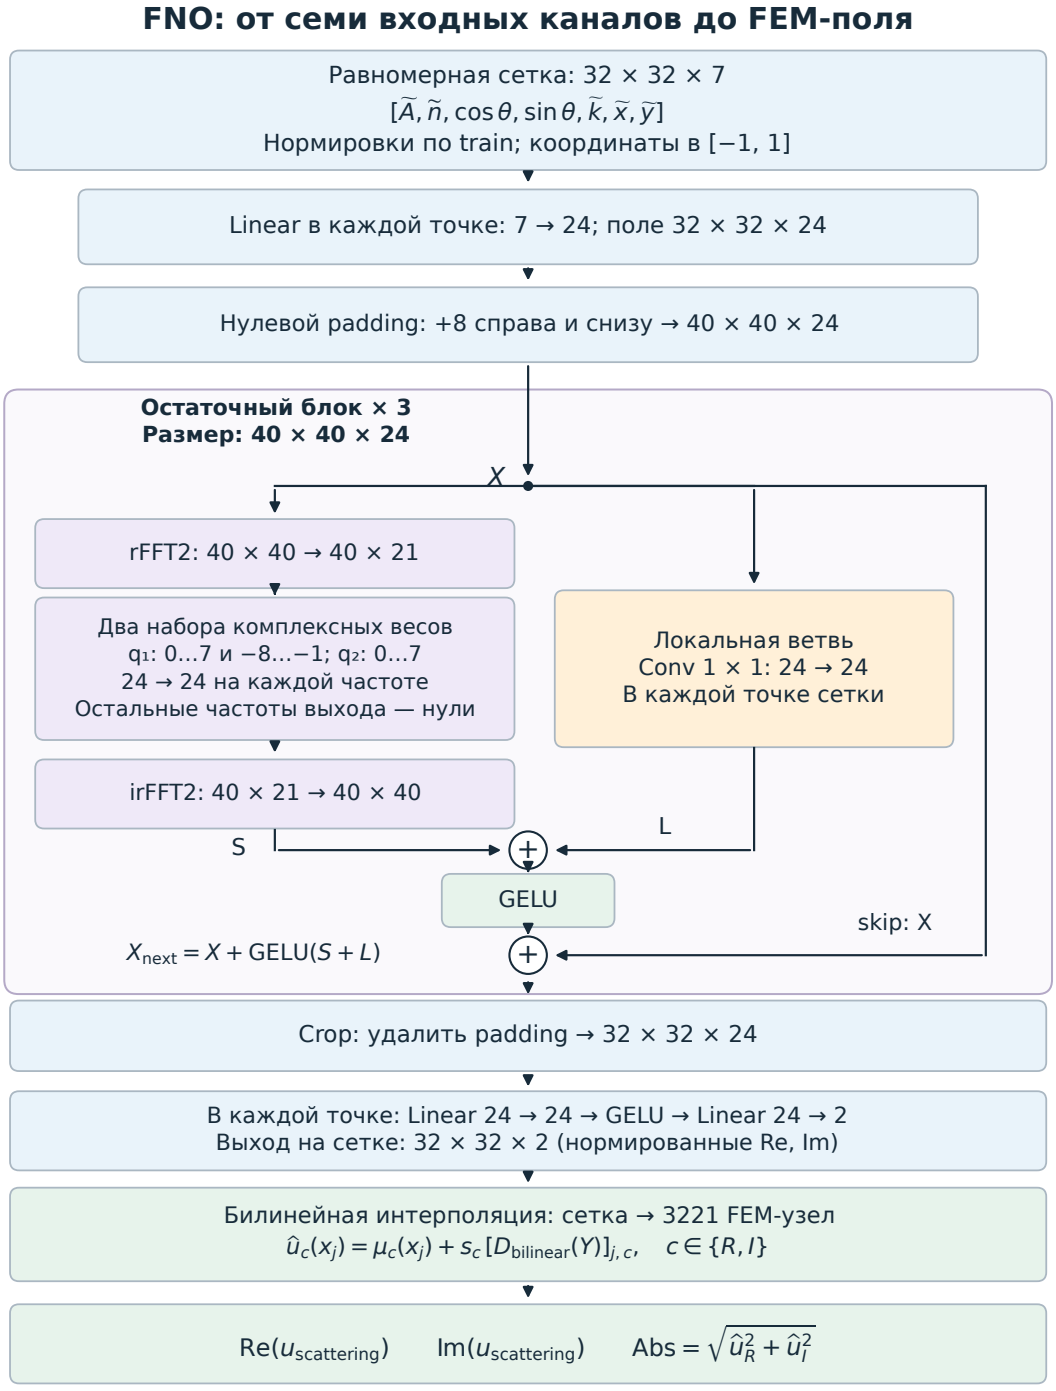


Рис. 4: Текущая архитектура FNO для статических наборов: семь входных каналов, три остаточных блока и восстановление рассеянного поля в FEM-узлах. S — спектральная ветвь с обучаемыми комплексными весами, L — локальная свёртка 1×1; прямая связь переносит вход X блока. $\mu_c(x_j)$ — среднее поле в узле, s_c — общий масштаб компоненты, оба определяются по обучающей выборке. Размеры показаны без оси пакета, каналы указаны последними. Модуль вычисляется из восстановленных Re и Im.

5. ФУНКЦИЯ ПОТЕРЬ И МЕТРИКИ ОШИБКИ

Введём остаток проекции $\boldsymbol{\rho}^{(s)} = \boldsymbol{u}^{(s)} - \boldsymbol{u}_R^{(s)}$. Ортонормированность выходных базисов в евклидовом скалярном произведении даёт тождество

$$\|\widehat{\boldsymbol{u}}^{(s)} - \boldsymbol{u}^{(s)}\|_2^2 = \|\widehat{\boldsymbol{c}}_{\mathrm{re}}^{(s)} - \boldsymbol{c}_{\mathrm{re}}^{(s)}\|_2^2 + \|\widehat{\boldsymbol{c}}_{\mathrm{im}}^{(s)} - \boldsymbol{c}_{\mathrm{im}}^{(s)}\|_2^2 + \|\boldsymbol{\rho}^{(s)}\|_2^2. \tag{24}$$

Оно справедливо для любого предсказания, восстановленного в тех же аффинных пространствах. Поэтому ошибка проекции является нижней границей узловой ошибки такой модели для каждого примера. В вычислениях тождество выполняется с точностью ортогонализации базисов.

Пусть D_{re} и D_{im} — диагональные матрицы масштабов из (13). Используемая функция потерь записывается явно:

$$\mathcal{L}(\boldsymbol{\eta}) = \frac{1}{N_{\mathrm{tr}}} \sum_{s \in \mathcal{I}_{\mathrm{tr}}} \left[\frac{\displaystyle\sum_{q \in \{\mathrm{re},\mathrm{im}\}} \|D_q(\widehat{\widetilde{\boldsymbol{c}}}_q^{(s)} - \widetilde{\boldsymbol{c}}_q^{(s)})\|_2^2 + \|\boldsymbol{\rho}^{(s)}\|_2^2}{\|\boldsymbol{u}^{(s)}\|_2^2} \right]^{1/2}, \tag{25}$$

где $\boldsymbol{\eta}$ — параметры сети. Благодаря (24) это средняя относительная узловая ошибка поля. Возврат масштабов D_q сохраняет физический вклад мод; равные веса нормированных коэффициентов задавали бы другую метрику. Остаток проекции в (25) учитывается внутри квадратного корня.

Для оценки на отложенных данных используются

$$e_{\mathrm{node}}^{(s)} = \frac{\|\widehat{\boldsymbol{u}}^{(s)} - \boldsymbol{u}^{(s)}\|_2}{\|\boldsymbol{u}^{(s)}\|_2}, \qquad e_{L^2}^{(s)} = \left(\frac{(\widehat{\boldsymbol{u}}^{(s)} - \boldsymbol{u}^{(s)})^* M (\widehat{\boldsymbol{u}}^{(s)} - \boldsymbol{u}^{(s)})}{(\boldsymbol{u}^{(s)})^* M \boldsymbol{u}^{(s)}} \right)^{1/2}. \tag{26}$$

Здесь * означает эрмитово сопряжение, а M — согласованная матрица масс для невзвешенной нормы $L^2(\Omega)$, отличная от $M(n)$ в (6). На треугольнике T её локальный блок равен

$$M_T = \frac{|T|}{12} \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}.$$

Эта формула точно интегрирует квадрат модуля кусочно-линейного поля на дискретной сетке. На неравномерной сетке узловая и интегральная нормы различаются. Евклидова SVD-проекция не обязана минимизировать ошибку в норме с матрицей M, поэтому вычисленная для неё ошибка L^2 служит диагностикой сжатия, а не доказанной нижней границей для этой нормы.

6. ОРГАНИЗАЦИЯ ЭКСПЕРИМЕНТА

Сформированы 1000 независимых реализаций среды. Для каждой выбирается угловой сдвиг θ_0, равномерно распределённый на $[0, \pi/4)$, и восемь направлений

$$\theta_j = \theta_0 + \frac{2\pi j}{8}, \qquad j = 0, \ldots, 7.$$

Всего получено 8000 комплексных полей. Случайное разбиение выполняется по идентификаторам сред: все восемь направлений одной среды относятся к одной части выборки (табл. 2). Тем самым обучение и оценка не используют разные направления одной и той же реализации

Таблица 2: Разбиение данных и назначение выборок

Выборка	Среды	Поля	Назначение
Обучающая	800	6400	Базисы, нормировки, веса сети
Валидационная	100	800	Выбор ранга и состояния сети
Тестовая	100	800	Оценка зафиксированной модели

материала в разных частях выборки. Одновременно со средой удерживается и связанное с ней значение k; оценка характеризует новые совместные реализации в диапазонах (4).

Сеть обучается методом Adam с размером пакета 256. Перед обновлением градиент ограничивается по глобальной норме значением 1. Начальный шаг 10^{-3} уменьшается вдвое после каждых 100 эпох с нижним ограничением 10^{-5}. В пределах 500 эпох это ограничение ещё не достигается: на последнем участке используется $6{,}25 \cdot 10^{-5}$. Для инициализации сети и перемешивания пакетов используется seed 42; seed генерации данных и разбиения равен 2026.

После каждой эпохи вычисляется валидационная ошибка. Для итоговой оценки выбирается состояние с наименьшим её значением. Отдельный критерий ранней остановки отслеживает отсутствие улучшения более чем на 10^{-4} на протяжении 80 эпох; проверка остановки начинается после 100 эпох. Предельная длительность запуска равна 500 эпохам. В рассматриваемом запуске достигнут этот предел, критерий ранней остановки не сработал, а лучшая валидационная ошибка получена на эпохе 500.

Числа в следующем разделе приведены по сохранённым результатам вычислительного эксперимента на базе DOLFINx и JAX. Они относятся к полному SVD и одному запуску обучения; оценка разброса по нескольким инициализациям не выполнялась.

6.1. Разные серии и уровень доступных свидетельств

Таблица 3 фиксирует единицу разбиения и смысл каждой проверки. Базисы и статистики вычисляются только по train; validation выбирает ранг и состояние сети. Процент в таблице результатов означает среднее индивидуальных относительных ошибок, умноженное на 100, а не отношение суммарных норм всех полей.

Таблица 3: Серии экспериментов: какие запросы удерживаются для проверки

Серия	Данные	Разбиение train/val/test	Что проверяется
Архивный JAX	1000 сред, 8000 полей; 11 380 узлов	800/100/100 сред	Новые среды и связанные с ними параметры волны
Пилот PyTorch	48 сред, 192 поля; 3221 узел	32/8/8 сред	Обобщение при малом числе обучающих материалов
Статическая PyTorch	1 среда, 8000 полей на полосу; 3221 узел	670/170/160 частот	Удержанные частоты той же среды

Для JAX доступны исходные ячейки и записанные outputs, но dataset и checkpoint в составе статьи отсутствуют. Поэтому его таблица проверяется по сохранённому журналу, а не новым независимым обучением. Для статических моделей доступны данные, веса, предсказания и per-sample ошибки; рисунки восстанавливаются из этих артефактов без обучения. Для пилота отдельно сохраняются архивные таблицы ошибок и конфигурация фактически

доступных весов. Эта градация свидетельств не позволяет называть все строки одинаково воспроизведёнными.

7. РЕЗУЛЬТАТЫ И ИХ ОБСУЖДЕНИЕ

Минимальная средняя валидационная узловая ошибка составила 7,0973% на 500-й эпохе. Среднее обучающее значение функции потерь на этой эпохе равно приблизительно 6,6975%. Обучающее значение усредняется по пакетам в процессе обновления параметров, а валидационное вычисляется для фиксированного состояния сети в конце эпохи; они не являются двумя оценками одного и того же состояния во время обучения.

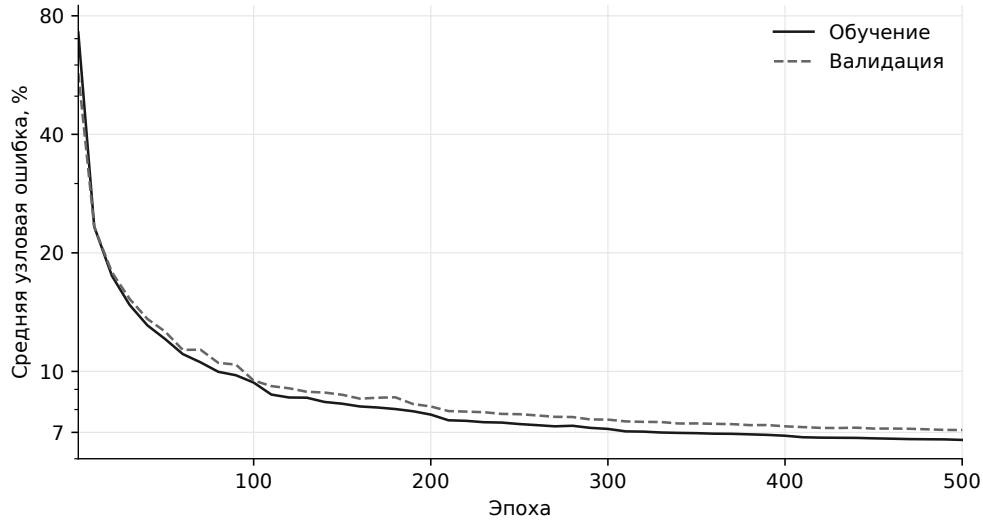


Рис. 5: Средняя относительная узловая ошибка при обучении с полным SVD. Показаны записанные в журнале значения на первой и каждой десятой эпохе, соединённые отрезками; вертикальная шкала логарифмическая.

Рисунок 5 показывает замедление уменьшения ошибки после начального этапа. Продолжающееся улучшение к концу интервала и остановка по лимиту эпох не позволяют утверждать достижение сходимости.

Тестовые характеристики выбранного состояния приведены в табл. 4. Для сравнения на тех же полях вычислена проекция (11), использующая истинные коэффициенты решения. Такая проекция не является самостоятельным предсказателем для новой задачи, поскольку требует знания искомого поля.

Таблица 4: Исторический JAX-эксперимент: относительные ошибки на 800 тестовых полях, %; $R = 71$ для каждой части решения

Приближение	Норма	Средняя	Медиана	95-й проц.	Максимум
SVD-проекция	Узловая	0,9221	0,7498	2,2828	3,5029
SVD-SNO	Узловая	6,8833	6,2593	13,3105	20,6574
SVD-проекция	L^2, матрица M	0,6961	0,5726	1,6452	2,6688
SVD-SNO	L^2, матрица M	6,4549	5,9376	12,2804	19,3278

Средняя узловая ошибка сети примерно в 7,46 раза превышает среднюю ошибку проекции. При фиксированных выходных пространствах разложение (24) связывает дополнительную ошибку с предсказанием коэффициентов. Это указывает на необходимость исследовать

обучение отображения при уже достаточно точном пространственном представлении. Разность или отношение средних ошибок не является аддитивным разложением ошибки; тождество (24) относится к квадратам норм каждого отдельного примера.

Средняя тестовая ошибка ниже валидационной; при одном разбиении это различие выборок не доказывает улучшения качества на новых данных. Направления одной среды зависимы: 800 тестовых полей соответствуют 100 отложенным средам. Доверительные интервалы по средам и разброс по повторным запускам не оценивались.

Отдельная диагностика рандомизированного SVD [5] с 136 вычисляемыми модами, 10 дополнительными векторами и двумя степенными итерациями также дала $R = 71$ и среднюю валидационную ошибку проекции 0,9696%. Близость ошибок представления не устанавливает одинаковую точность обучения двух сетей или ускорение полного вычислительного процесса.

Ошибки вычислены относительно дискретного решения (5); сеточная и граничная погрешности отдельно не оценены. Перенос на другие положения включений, сетки и волновые числа вне (4) не проверялся. Оценка ускорения требует измерения полного пути предсказания при заданной точности с отдельным учётом формирования данных, базисов и обучения.

7.1. Статическая среда: сопоставление FEM, SVD-SNO и FNO

Для наглядного показа Re, Im и Abs использованы сохранённые модели SVD-SNO для *одной фиксированной среды* в диапазонах $k \in [1, 2]$ и $k \in [4, 8]$. В каждом диапазоне сформированы 1000 значений частоты и по восемь направлений падающей волны на каждую частоту, то есть 8000 полей; набор углов задаётся отдельно для каждой частоты; сетка содержит 3221 узел и 6280 треугольников. Для каждого диапазона обучена отдельная PyTorch-модель с рандомизированным POD. Эти статические расчёты представляют другой эксперимент, чем исторический JAX-запуск табл. 4, и не заменяют его результаты.

Материал этой серии задаётся тремя активными кругами из табл. 5; вне них $A = n = 1$. Координаты, радиусы и коэффициенты получены из сохранённых geometry и DG0-массивов, а не подобраны по ошибке сети. Числа в таблице округлены для чтения; при воспроизведении используются исходные массивы. Частоты расположены равномерно: $k_f = k_{\min} + (k_{\max} - k_{\min})f/999,\ f = 0, \ldots, 999$.

Таблица 5: Фиксированная среда статического примера

x_c	y_c	Радиус	A	n
$-0,6$	$0,1$	$0,05$	0,69286575	2,59454354
$0,4$	0	$0,10$	0,86604243	1,69621106
$-0,3$	$-0,3$	$0,05$	0,78180951	1,84454536

Разбиение здесь выполняется по частотам: все восемь направлений для одного значения k остаются в одной части выборки. Обучающая, валидационная и тестовая части содержат соответственно 670/170/160 частотных групп, то есть 5360/1360/1280 полей. Поэтому тест характеризует предсказание на удержанных частотах той же среды. Он не оценивает перенос на новые материалы, в отличие от разбиения по средам в основном эксперименте.

Поскольку A и n одинаковы во всех примерах статического набора, их центрированные матрицы снимков нулевые и оба входных POD-ранга равны нулю. Вход SVD-SNO состоит из трёх признаков: $\cos\theta$, $\sin\theta$ и нормированного k. Обе SVD-SNO имеют ширину 24 и три остаточных блока, обучены 200 эпох; лучшие валидационные состояния выбраны на эпохах 170 и 198. Для низкого диапазона дополнительно обучена FNO с архитектурой рис. 4. Её обучение остановлено после 142 эпох без улучшения валидационной ошибки в течение 50 эпох, лучшее состояние получено на эпохе 92.

Сохранённые конфигурации задают начальный шаг 0,002, пакет 32, seed 42, предел 200 эпох и выбор состояния только по валидационной FEM-ошибке. Исполняемый PyTorch-цикл использует AdamW с weight decay 10^{-5} и ограничением нормы градиента до 1. Состояние оптимизатора в старых bundles отсутствует; указанный выбор проверяется по коду, а не восстанавливается из весов. Ширина 24 и глубина 3 у SVD-SNO и FNO не означают одинаковую ёмкость: число параметров приведено в табл. 6. Комплексный вес FNO учитывается как два вещественных параметра. SVD-SNO обучены на CPU, FNO — на Apple M4 через MPS; время обучения между этими устройствами не сравнивается.

В этой серии POD строится с диагональной массой $W = \mathrm{diag}(M\mathbf{1})$, а ошибка измеряется согласованной матрицей M. Для матрицы снимков со строками-примерами разлагается $F_c W^{1/2} = U\Sigma V^{\mathsf{T}}$, затем

$$\Phi = W^{-1/2}V_r, \qquad \Phi^{\mathsf{T}}W\Phi = I, \qquad \boldsymbol{c}_W = \Phi^{\mathsf{T}}W(\boldsymbol{f} - \boldsymbol{m}). \tag{27}$$

Рандомизированное разложение использует 10 дополнительных направлений и две степенные итерации. Средняя валидационная FEM-ошибка реконструкции определяет общий выходной ранг. Для низкой полосы цель 1% достигнута при 10 модах; для высокой выбран предел 48, но цель не достигнута. Флаг этого ограничения сохранён в результатах.

Для обучения в той же FEM-метрике вводятся $G = \Phi^{\mathsf{T}}M\Phi$, коэффициенты согласованной проекции $\boldsymbol{c}_* = G^{-1}\Phi^{\mathsf{T}}M(\boldsymbol{f} - \boldsymbol{m})$ и остаток $\boldsymbol{r} = \boldsymbol{f} - \boldsymbol{m} - \Phi\boldsymbol{c}_*$. Тогда для каждого вещественного компонента

$$\|\boldsymbol{f} - \boldsymbol{m} - \Phi\widehat{\boldsymbol{c}}\|_M^2 = (\widehat{\boldsymbol{c}} - \boldsymbol{c}_*)^{\mathsf{T}}G(\widehat{\boldsymbol{c}} - \boldsymbol{c}_*) + \|\boldsymbol{r}\|_M^2. \tag{28}$$

Сумма выражений для Re и Im даёт комплексную ошибку. Коэффициенты сети сначала денормируются. Это позволяет вычислять loss без реконструкции всех узлов каждого пакета. Проекция с $\boldsymbol{c}_*$ минимизирует ошибку в том же аффинном пространстве для нормы M; реконструкция с $\boldsymbol{c}_W$ в общем случае такого свойства не имеет. Средние тестовые ошибки последней равны 0,9189% и 1,2690%; соответствующие согласованные минимумы — 0,9188% и 1,2686%.

Таблица 6: Статическая среда, удержанные частоты: относительные ошибки в комплексной FEM-норме L^2, %; число вещественных обучаемых параметров

Диапазон k	Модель	Ранги	Парам.	Средняя	Медиана	p95	Макс.
$[1, 2]$	SVD-SNO	10/10	3 110	0,9614	0,8824	1,6792	2,9480
$[1, 2]$	SVD-SNO v2	10/10	4 022	0,9475	0,8671	1,6534	2,8962
$[1, 2]$	FNO	—	445 010	1,6599	1,6329	1,9505	2,2305
$[1, 2]$	Chebyshev-SNO	—	2 426	7,9364	7,6838	9,8811	11,1065
$[4, 8]$	SVD-SNO	48/48	13 370	5,5375	5,0683	9,0357	17,8595

Новая SVD-SNO версии 2 обучена отдельно на том же low-band наборе с теми же POD-рангами и seed 42; её строка явно помечена v2. Выполнено 165 эпох, лучшее состояние — 115-я эпоха, остановка — после 50 эпох без улучшения validation. Средняя ошибка уменьшилась с 0,9614% до 0,9475%, при увеличении числа параметров с 3110 до 4022. Это одиночная реализация двух архитектур с малой разницей ошибок; она не устанавливает статистически подтверждённого преимущества v2. Иллюстрации ниже сохраняют исходные legacy-предсказания.

На тех же статических low-band данных выполнено отдельное обучение Chebyshev-SNO: 200 эпох, лучшее validation-состояние на эпохе 199, test mean=7,9364%. Используются 8×8 полиномов на сетке 32×32, ширина 24 и три блока; число параметров — 2426. Для этого фиксированного декодера оптимальная согласованная проекция в его аффинное выходное пространство даёт среднюю validation-ошибку 7,6143%. Поэтому точность 1% на этой выборке

недостижима одним изменением весов сети при неизменном декодере. Эта новая строка характеризует один материал, а не пилот новых сред из следующего подраздела. Вывод относится к выбранным модам и переносу в FEM-узлы; он не устанавливает общий предел полиномов Чебышёва.

На рис. 6–8 показаны примеры, типичные по значению комплексной FEM-ошибки L^2. В каждом диапазоне из всех 1280 тестовых полей выбирается поле с ошибкой, ближайшей к медиане ошибок SVD-SNO этого набора. При равных расстояниях берётся первая позиция сохранённого тестового списка. Для низкого диапазона выбран индекс 2211, $k = 1{,}27628$, $\theta = 2{,}78201$ рад; для высокого — индекс 6077, $k = 7{,}03904$, $\theta = 4{,}24536$ рад. Этот критерий иллюстрирует типичный уровень выбранной метрики, а разброс по тесту характеризуется табл. 6.

В строках рисунков приведены Re, Im и Abs; в столбцах — FEM, предсказание SVD-SNO и абсолютная ошибка выбранной компоненты. Для низкого диапазона обе модели показаны на одном поле, выбранном по SVD-SNO, с общей цветовой шкалой FEM и обоих предсказаний каждой компоненты и общей шкалой ошибок. Таким образом, FNO не получает отдельный отобранный пример. Третья строка ошибок показывает $\big||\widehat{u}_s| - |u_s|\big|$, а не $|\widehat{u}_s - u_s|$. Ошибка отдельного примера и средняя ошибка набора являются разными характеристиками.

7.2. Высокая частота: перенос модели и проверка FEM-меток

Предсказание отдельной high-band сети в табл. 6 нельзя трактовать как перенос обученной low-band модели. При замороженных весах, базисах и нормировках низкой полосы средняя ошибка на тех же 1280 high-band полях равна 144,1781%, p95 — 154,9587%, максимум — 174,0839%. Средняя ошибка реконструкции в замороженном low-band POD-пространстве составляет 96,7713%. Следовательно, уже представление поля плохо переносится на новую полосу; переобучение меняет как базис, так и отображение коэффициентов.

Для трёх наибольших удержанных частот выполнен отдельный FEM-расчёт с целевым шагом $h = 0,05$ вместо $h = 0,1$; число узлов выросло с 3221 до 8958. Исходное P1-поле интерполировано в узлы уточнённой сетки. Изменение измеряется относительно уточнённого решения в его согласованной норме L^2:

$$\delta_h = \frac{\|I_{h\to h/2}u_h - u_{h/2}\|_{M_{h/2}}}{\|u_{h/2}\|_{M_{h/2}}}. \tag{29}$$

Таблица 7: Статическая высокая полоса: изменение дискретного FEM-решения

Индекс поля	k	$100\delta_h$, %
7904	7,95596	13,6564
7888	7,94795	13,5935
7784	7,89590	13,3219

Изменение на 13–14% больше средней ошибки сети 5,54% к исходным меткам. Проверка включает погрешность переноса и не является строгой оценкой ошибки относительно непрерывной задачи. Тем не менее она не подтверждает достаточную точность $h = 0,1$ для физического вывода в этой полосе. Поэтому high-band серия используется как проверка усложнения дискретного отображения. Требуются дальнейшее уточнение сетки и отдельная проверка внешнего поглощающего условия. Само увеличение разрешения FNO или ранга POD эту неопределённость FEM-меток не устраняет.

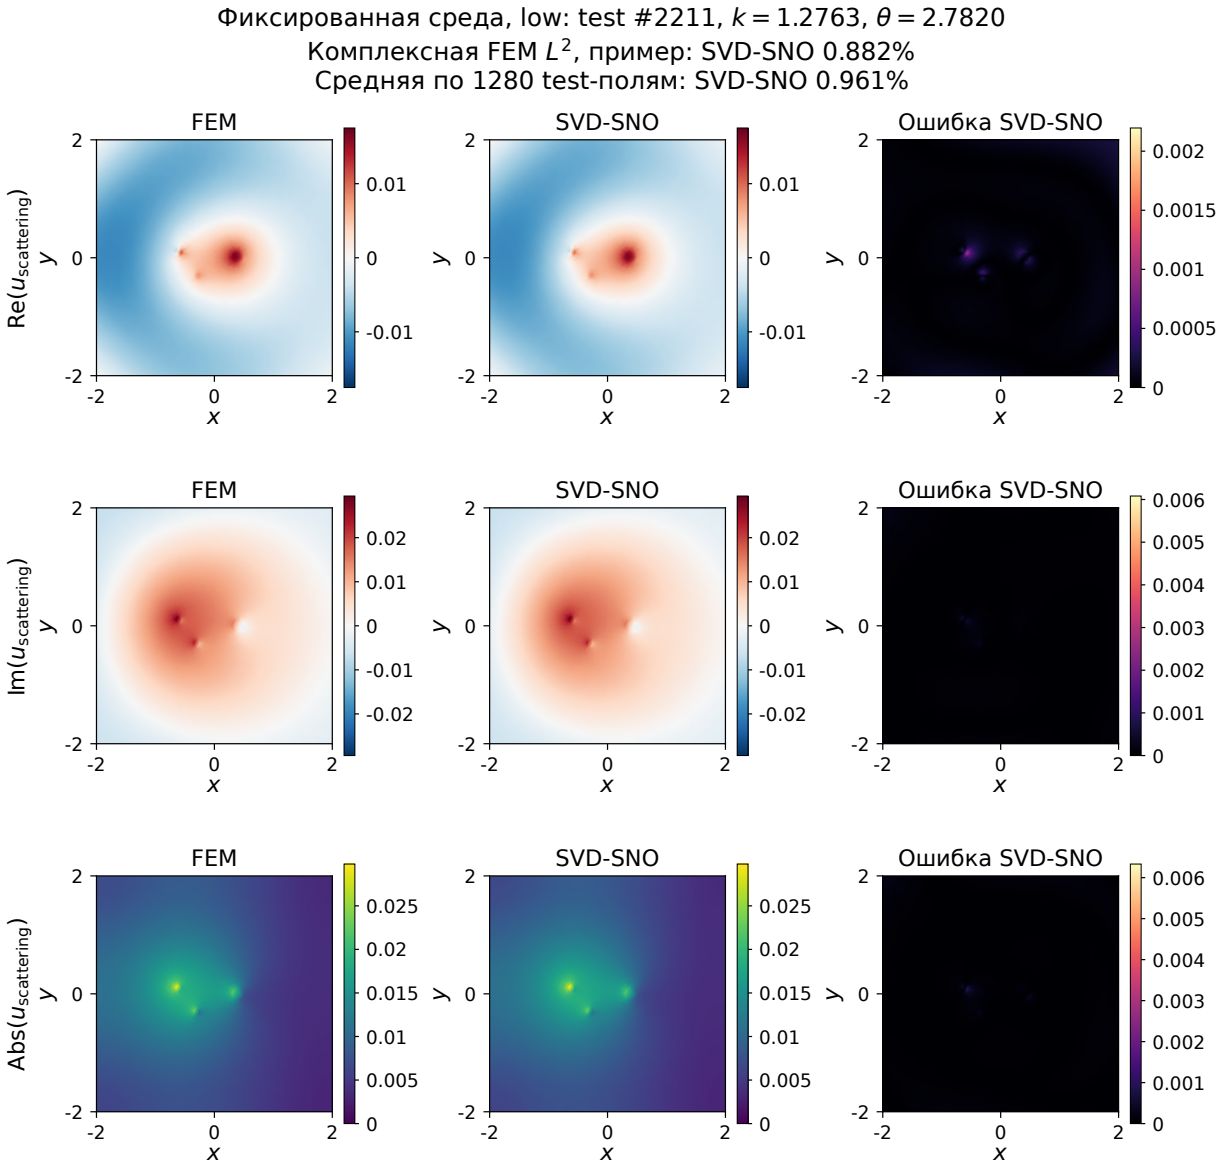


Рис. 6: Статическая среда, $k \in [1, 2]$: FEM и randomized SVD-SNO для примера, ближайшего к медиане тестовых ошибок, $k = 1{,}27628$. Строки: Re, Im и Abs; столбцы: FEM, предсказание и абсолютная ошибка компоненты. Относительная комплексная FEM-ошибка L^2 примера равна 0,8825%, средняя на всём тестовом наборе — 0,9614%. С FNO на рис. 7 согласованы поле и цветовые шкалы.

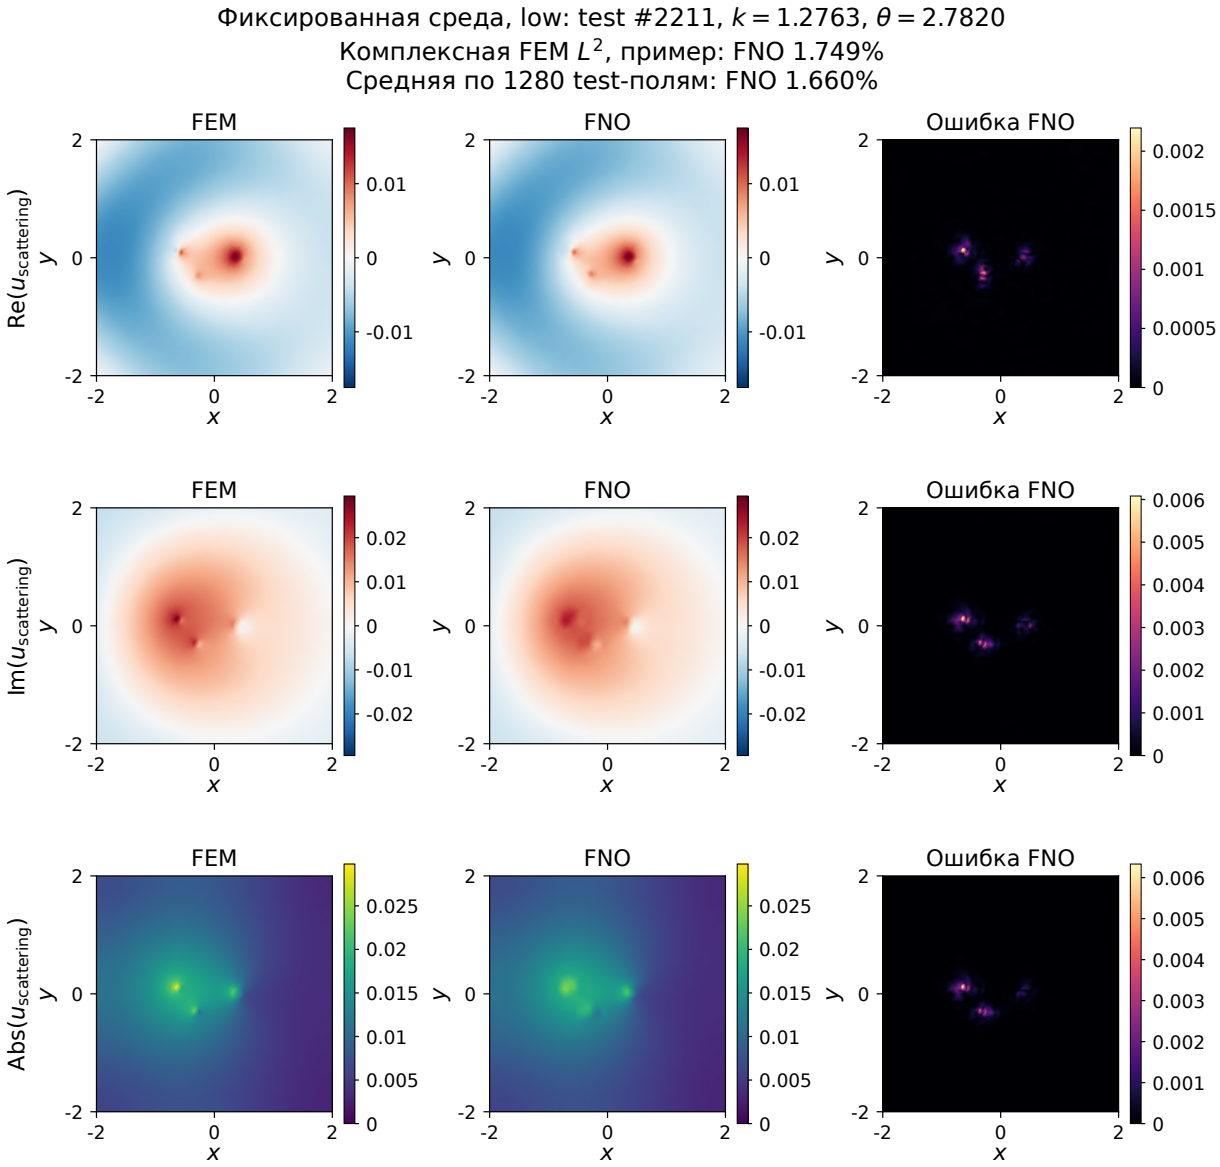


Рис. 7: Статическая среда, $k \in [1, 2]$: FEM и FNO на том же примере 2211, что на рис. 6, $k =$ 1,27628. Строки: Re, Im и Abs; столбцы: FEM, предсказание и абсолютная ошибка компоненты. Комплексная FEM-ошибка примера — 1,7488%, средняя на всём тестовом наборе — 1,6599%. Цветовые шкалы согласованы с SVD-SNO. Пример выбран по медиане ошибок SVD-SNO, а не по ошибке FNO.

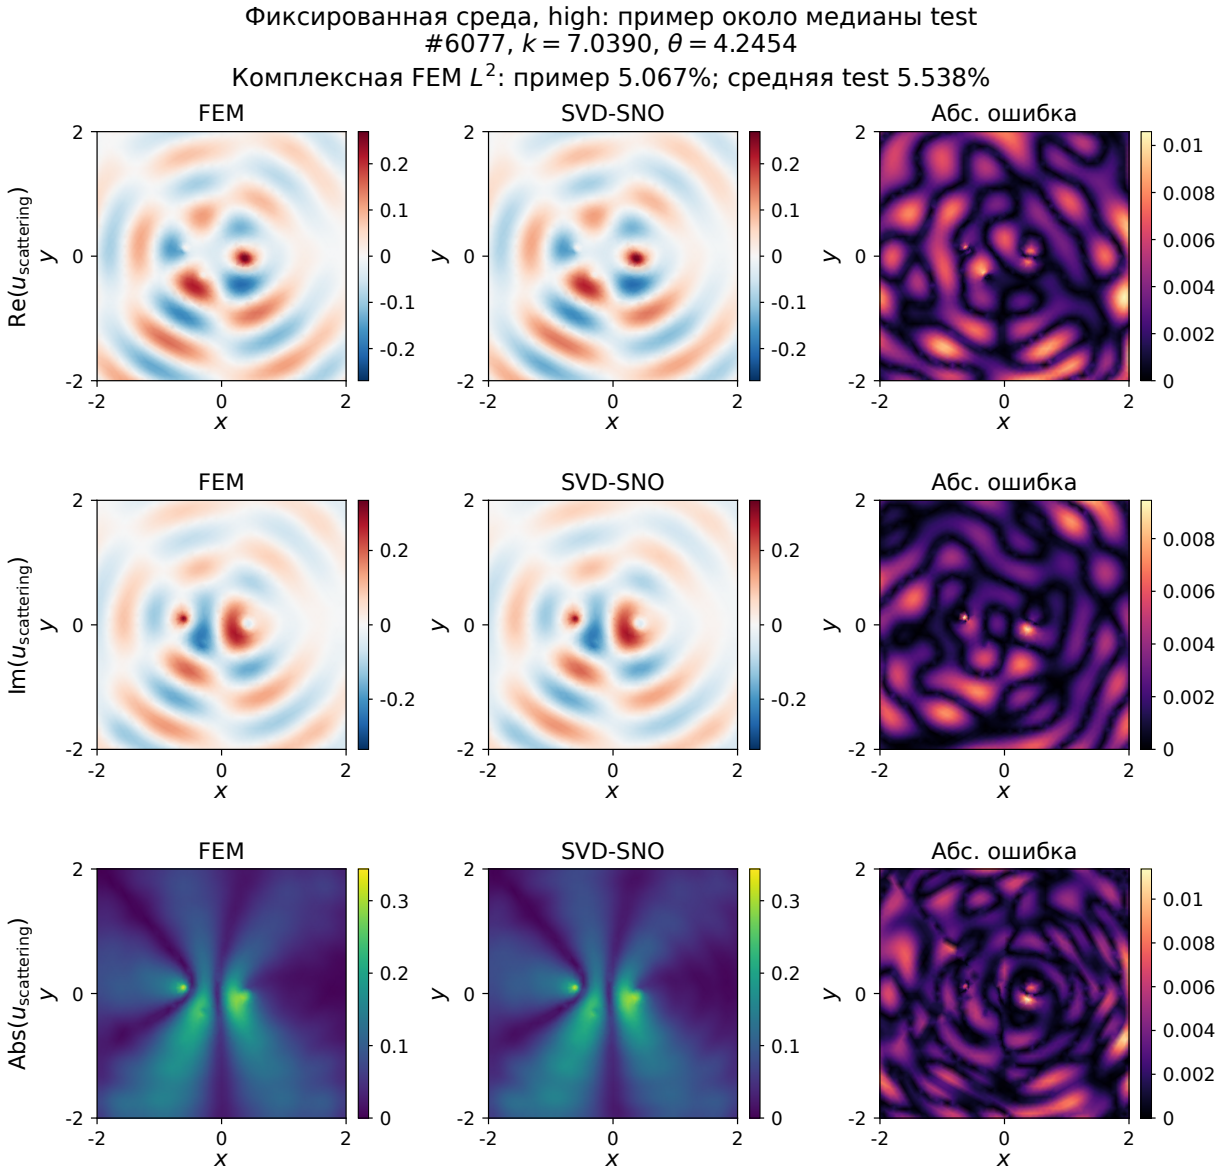


Рис. 8: Статическая среда, $k \in [4, 8]$: FEM, randomized SVD-SNO и абсолютная ошибка компоненты для примера, ближайшего к медиане тестовых ошибок, $k = 7{,}03904$. Строки: Re, Im и Abs. Относительная комплексная FEM-ошибка L^2 примера составляет 5,0670%, средняя на всём тестовом наборе — 5,5375%. Для этого диапазона обучена отдельная модель; переноса низкочастотной модели здесь нет.

7.3. Новые среды: пилот SVD-SNO, Chebyshev-SNO и FNO

В пилоте используются 48 материалов, по четыре направления на материал и одна случайная частота на среду: 192 поля при $h = 0,1$. Разбиение по средам даёт 128/32/32 поля. Обе полосы используют одинаковые материалы и групповые индексы, а high-band FEM-поля вычислены заново. Это более трудная проверка изменения материала, но значительно меньшая обучающая выборка, чем в JAX-серии. Она не служит оценкой того, что статическая модель умеет переноситься на новую среду.

Таблица 8 относится к архивной серии с width=24, depth=3, batch=32, lr=0,002, seed=42 и пределом 200 эпох. Выходной предел POD равен 48; у Chebyshev-SNO и FNO сохраняется по восемь мод на ось при сетке 32×32. Средняя тестовая ошибка POD-реконструкции SVD-SNO равна 2,67%; валидационная цель 1% при этом пределе не достигнута. Размеры моделей существенно различаются, поэтому общий предел эпох не означает одинаковые затраты вычислений.

Таблица 8: Архивный пилот, новые среды, $k \in [1, 2]$: комплексная FEM-ошибка L^2, %

Метод	Параметры	Средняя	Медиана	p95	Максимум
SVD-SNO	68 666	68,5807	63,0559	106,5878	118,3999
Chebyshev-SNO	2 426	70,6241	72,6810	82,7032	85,2284
FNO	445 010	38,8387	37,2024	59,6493	67,3809

Лучшее состояние архивной SVD-SNO получено на восьмой эпохе из 58. Chebyshev-SNO и FNO достигли 200 эпох; лучшие состояния выбраны на эпохах 196 и 194. Ошибки велики у всех трёх методов. Разрыв POD-реконструкции и ошибки SVD-SNO показывает ограничение обучения коэффициентов на этой выборке. Он не доказывает, что одного увеличения ранга достаточно для обобщения на новые материалы.

В фактически доступной директории low-band SVD сохранён *другой* запуск: width=64, depth=4, ранг Re/Im=85, batch=128, предел 500 эпох. Его 328 550 параметров дают среднюю тестовую ошибку 74,0115% и p95 100,6768%; выбрана эпоха 16 из 66. Ошибка POD-реконструкции равна 0,9435%. Этот checkpoint не подменяет архивную строку 68,5807%: исходная таблица и её per-sample ошибки сохранены отдельно, но старое low-band SVD-состояние этой таблицы независимо не восстановлено. Улучшение пространственной реконструкции в другом запуске не привело к уменьшению сетевой ошибки.

Таблица 9: Тот же архивный пилот на $k \in [4, 8]$: frozen — всё состояние низкой полосы заморожено; retrained — отдельные train-базисы, нормировки и обучение

Метод	Режим	Средняя, %	p95, %
SVD-SNO	frozen	112,5602	133,8522
Chebyshev-SNO	frozen	116,6925	149,6163
FNO	frozen	163,5729	271,5711
SVD-SNO	retrained	115,6862	134,5812
Chebyshev-SNO	retrained	100,8867	106,2159
FNO	retrained	93,5304	106,1455

У архивной SVD-SNO средняя ошибка POD-реконструкции меняется с 84,24% в замороженном пространстве до 24,26% после построения high-band базиса, однако ошибка сети остаётся выше 100%. Здесь одновременно меняются представление поля и обучаемое отображение.

Для трёх high-band полей пилота уточнение FEM-сетки также даёт изменение 11,50–14,94%. Поэтому табл. 9 характеризует приближение конкретных дискретных меток при малой выборке; она не доказывает невозможность нейрооператорного решения высокочастотной задачи.

Отдельный классический контроль использует три отложенные среды, по одному направлению на среду. GMsFEM строит локальные пространства для конкретных A, n, k и решает галеркинскую систему; нейросеть предсказывает коэффициенты без такого online-решения. При четырёх локальных модах сохранённые средние ошибки GMsFEM Type 1 и Type 2 равны 9,4564% и 8,5271%; для архивных SVD-SNO, Chebyshev-SNO и FNO на той же тройке — 61,8427%, 67,4883% и 39,5256%. Определение двух типов локальных пространств следует [4]. Эти три примера отличаются от полного neural test из 32 полей. Времена построения базисов, обучения и online-решения относятся к разным этапам; по этой малой серии коэффициент общего ускорения не заявляется.

7.4. Как проверить численные примеры

Сопроводительный файл `REPRODUCIBILITY.md` задаёт команды из корня проекта и точные пути для каждой серии. Команда `prepare_predictions.py` строит статические рисунки из сохранённых весов и данных; она не переобучает сеть и не решает FEM. Скрипт `validate_paper.py` сверяет сводки с per-sample таблицами, числа в тексте, локальные рисунки и LaTeX-ссылки. В `evidence/revision_2026-11-08/` сохранены использованные таблицы, конфигурации и SHA256 источников.

Полное повторение обучения — отдельная операция. Оно должно явно сохранять версию архитектуры, способ SVD, seed, групповые индексы и тип нормы. Запуск новых весов версии 2 не воспроизводит ошибки legacy. Для исторического JAX-эксперимента доступна проверка записанных outputs; для статических весов — также повторный инференс. Повторные seeds, доверительные интервалы по группам и независимое воспроизведение JAX-обучения в настоящем редактировании не выполнялись.

8. ЗАКЛЮЧЕНИЕ

Рассмотрена адаптация спектрального предсказания коэффициентов к FEM-задаче рассеяния. Формулы кодирования, нормировки и ошибки позволяют различать ограничение выходного пространства и ошибку обучаемого отображения. Протокол разбиения определяет, относится ли оценка к новым материалам, к удержанным частотам одного материала или к переносу за пределы обученной полосы.

При 71 моде для каждой части поля средняя валидационная узловая ошибка проекции меньше 1%, а средняя тестовая ошибка сети в норме L^2 равна 6,455%. Различие ошибок проекции и сети указывает на необходимость улучшения предсказания коэффициентов. Дальнейшие задачи — повторные запуски, сравнение рангов, проверка сеточной сходимости и измерение вычислительной стоимости.

Для фиксированной среды средние FEM-ошибки randomized SVD-SNO составляют 0,9614% и 5,5375% при отдельном обучении на двух полосах. Замороженная низкочастотная модель даёт 144,1781% на высокой полосе. Изменение high-band FEM-меток на 13–14% при уточнении сетки ограничивает физическую интерпретацию малой surrogate-ошибки. Архивный пилот на новых средах сохраняет большие ошибки SVD-SNO, Chebyshev-SNO и FNO; его результаты не заменяются успешной интерполяцией по частоте. Дальнейшее сравнение требует уточнённых FEM-данных, нескольких инициализаций и согласованного вычислительного бюджета.

ЛИТЕРАТУРА

1. Li Z., Kovachki N., Azizzadenesheli K., Liu B., Bhattacharya K., Stuart A., Anandkumar A. Fourier Neural Operator for Parametric Partial Differential Equations. ICLR. 2021. arXiv:2010.08895v3.

2. Fanaskov V., Oseledets I. Spectral Neural Operators. 2022; версия 2, 2024. arXiv:2205.10573v2.
3. Lu L., Meng X., Cai S., Mao Z., Goswami S., Zhang Z., Karniadakis G. E. A comprehensive and fair comparison of two neural operators (with practical extensions) based on FAIR data. Computer Methods in Applied Mechanics and Engineering. 2022. Vol. 393. Art. 114778. doi:10.1016/j.cma.2022.114778.
4. Kalachikova U., Vasilyeva M., Harris I., Chung E. T. Generalized Multiscale Finite Element Method for scattering problem in heterogeneous media. Journal of Computational and Applied Mathematics. 2023. Vol. 424. Art. 114977. doi:10.1016/j.cam.2022.114977.
5. Halko N., Martinsson P.-G., Tropp J. A. Finding Structure with Randomness: Probabilistic Algorithms for Constructing Approximate Matrix Decompositions. SIAM Review. 2011. Vol. 53, No. 2. P. 217–288. doi:10.1137/090771806.