Нейросетевое приближение рассеянного поля при фиксированной среде: SVD-SNO, FNO и Chebyshev-SNO

Аннотация. Рассматривается двумерная задача рассеяния плоской волны на трёх проницаемых круговых включениях с фиксированными коэффициентами материала. По волновому числу и направлению волны предсказывается комплексное рассеянное поле на заданной конечно-элементной сетке. Сопоставляются SVD-SNO с модами, найденными по снимкам решения, FNO с преобразованиями Фурье и Chebyshev-SNO с фиксированным полиномиальным представлением. Для 1000 частот из диапазона $k \in [1, 2]$ и восьми направлений на каждую частоту сформированы 8000 FEM-полей. Разбиение выполняется по частотам: все направления одной частоты относятся к одной части выборки. На 1280 тестовых полях средние ошибки относительно FEM-меток в согласованной комплексной норме L^2 составили 0,9475% для SVD-SNO, 1,6599% для FNO и 7,9364% для Chebyshev-SNO. Выход SVD-SNO использует по десять POD-мод для действительной и мнимой частей. Для Chebyshev-SNO при 8×8 модах средняя оптимальная ошибка её фиксированного декодера на валидации равна 7,6143%. Результаты относятся к удержанным частотам одного материала и одному seed; точность относительно непрерывной задачи отдельно не установлена.

Ключевые слова: уравнение Гельмгольца; рассеяние волн; метод конечных элементов; POD; спектральный нейрооператор; FNO; полиномы Чебышёва.

1. ВВЕДЕНИЕ

При фиксированной среде серия задач рассеяния различается частотой и направлением падающей волны. FEM-решение каждой задачи даёт дискретную опорную метку, а заранее обученная сеть может приближать зависимость поля от параметров волны. Цель данной работы — сопоставить три представления этого отображения на одном наборе данных и явно отделить точность выходного пространства от точности предсказания его коэффициентов.

В FNO обучаемая спектральная ветвь использует преобразование Фурье, а нелинейность действует на пространственные признаки [1]. В SNO функции представлены коэффициентами рядов, и сеть преобразует эти коэффициенты [2]. Здесь рассматриваются два coefficient-space варианта: SVD-SNO с POD-модами, найденными по FEM-снимкам, и Chebyshev-SNO с заранее заданными тензорными полиномами. Использование фиксированного POD-базиса для выходного поля известно также из POD-DeepONet [3]; приведённая ниже SVD-SNO имеет собственную формулу блока и не объявляется воспроизведением этой архитектуры.

Материал одинаков для всех примеров. Поэтому фактически изучается конечнопараметрическое отображение

$$\mathcal{G}_h : (k, \theta) \longmapsto u_{s,h}(\cdot; k, \theta), \qquad k \in [1, 2], \quad \theta \in [0, 2\pi). \tag{1}$$

Обозначения SNO и FNO описывают способ представления и обработки поля. Тест не проверяет новые материалы, геометрии или сетки. Для воспроизводимого сопоставления фиксируются FEM-метрика, групповые индексы, настройки моделей и сохранённые веса.

2. ЗАДАЧА РАССЕЯНИЯ И FEM-МЕТКИ

Пусть $\Omega = (-2, 2)^2$, а падающая волна равна

$$u_i(\boldsymbol{x}) = \exp(\mathrm{i}k\boldsymbol{d} \cdot \boldsymbol{x}), \qquad \boldsymbol{d} = (\cos\theta, \sin\theta). \tag{2}$$

Вещественные скалярные коэффициенты $A > 0$ и $n > 0$ постоянны внутри каждого круга; вне включений $A = n = 1$. Таблица 1 задаёт используемый материал. Координаты и коэффициенты округлены для чтения; расчёты используют исходные DG0-массивы. Геометрия показана на рис. 1.

Таблица 1: Одна фиксированная среда во всех обучающих и тестовых примерах

x_c	y_c	Радиус	A	n
$-0,6$	$0,1$	$0,05$	0,69286575	2,59454354
$0,4$	0	$0,10$	0,86604243	1,69621106
$-0,3$	$-0,3$	$0,05$	0,78180951	1,84454536

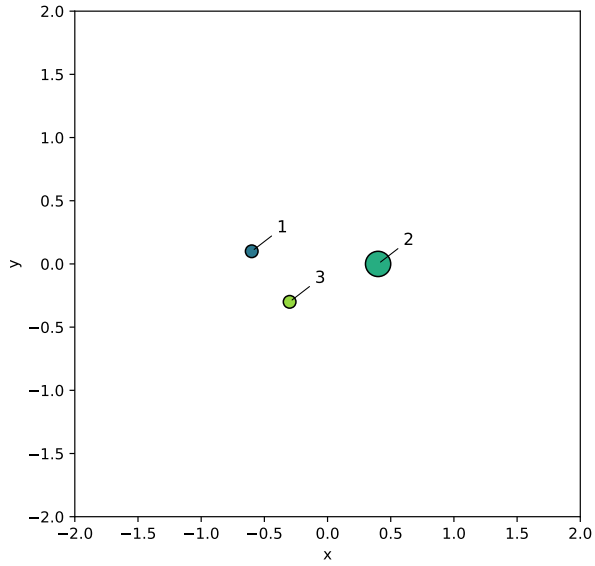


Рис. 1: Расчётная область и три активных включения. Цвет выделяет материальные области; нумерация соответствует строкам табл. 1.

Полное поле $u = u_i + u_s$ удовлетворяет уравнению $\nabla \cdot (A\nabla u) + k^2 n u = 0$. Для рассеянного поля

$$\nabla \cdot (A\nabla u_s) + k^2 n u_s = \nabla \cdot \big((1-A)\nabla u_i\big) + k^2(1-n)u_i. \tag{3}$$

На внешней границе задаётся локальное поглощающее условие первого порядка

$$A\partial_\nu u_s - \mathrm{i}k u_s = 0. \tag{4}$$

Все включения расположены внутри области; вблизи границы $A = n = 1$. Условие (4) задаёт ограниченную задачу с приближением излучения на конечном квадрате.

Пусть $V_h \subset H^1(\Omega;\mathbb{C})$ — пространство непрерывных кусочно-линейных функций. Найти $u_{s,h} \in V_h$, такое, что для любого $v_h \in V_h$

$$\begin{aligned} &\int_\Omega A\nabla u_{s,h} \cdot \nabla \overline{v_h}\, d\boldsymbol{x} - k^2 \int_\Omega n u_{s,h}\overline{v_h}\, d\boldsymbol{x} - \mathrm{i}k \int_{\partial\Omega} u_{s,h}\overline{v_h}\, ds \\ &\qquad = -\int_\Omega (A-1)\nabla u_i \cdot \nabla \overline{v_h}\, d\boldsymbol{x} + k^2 \int_\Omega (n-1) u_i \overline{v_h}\, d\boldsymbol{x}. \end{aligned} \tag{5}$$

При скачках A правая часть учитывает интерфейсный вклад в слабом смысле. Подстановка только объёмного выражения по материалам не эквивалентна (5). При $A = n = 1$ правая часть обращается в нуль.

Общая согласованная треугольная сетка содержит 3221 узел и 6280 треугольников; целевой фоновый шаг равен $h = 0,1$. Решается комплексная система

$$\big(K(A) - k^2 M(n) - \mathrm{i}k M_{\partial\Omega}\big)\boldsymbol{u}_s = \boldsymbol{b}(k,\theta) \tag{6}$$

с использованием LU. Исходные материальные коэффициенты задаются на ячейках. Для входа пространственных сетей они усредняются в узлах по прилегающим элементам с равными весами; FEM-сборка использует исходные DG0-поля.

3. ВЫБОРКА, НОРМИРОВКА И ОБЩАЯ МЕТРИКА

Частоты расположены равномерно:

$$k_f = 1 + \frac{f}{999}, \qquad f = 0, \ldots, 999. \tag{7}$$

Для каждой частоты воспроизводимо выбирается сдвиг $\theta_{0,f} \in [0, \pi/4)$ и восемь направлений $\theta_{f,j} = \theta_{0,f} + 2\pi j/8$, $j = 0, \ldots, 7$. Всего имеется 8000 комплексных полей. Частотные группы перемешиваются с seed 2026; все восемь направлений одной частоты остаются вместе.

Таблица 2: Групповое разбиение одной среды

Выборка	Частоты	Поля	Назначение
Обучающая	670	5360	Базисы, статистики, веса сети
Валидационная	170	1360	Выбор ранга и состояния сети
Тестовая	160	1280	Оценка зафиксированных моделей

Средние, масштабы и POD-моды вычисляются только по train. Углы представлены парой $(\cos\theta, \sin\theta)$, а частота нормируется обучающими средним и стандартным отклонением. Все методы предсказывают два вещественных канала. После восстановления физических масштабов

$$\widehat{u}_s = \widehat{u}_{\mathrm{re}} + \mathrm{i}\widehat{u}_{\mathrm{im}}, \qquad |\widehat{u}_s| = \sqrt{\widehat{u}_{\mathrm{re}}^2 + \widehat{u}_{\mathrm{im}}^2}. \tag{8}$$

Модуль вычисляется из восстановленного поля, а не из модулей его коэффициентов.

Основная ошибка для каждого примера равна

$$e_M = \left(\frac{(\widehat{\boldsymbol{u}} - \boldsymbol{u})^* M (\widehat{\boldsymbol{u}} - \boldsymbol{u})}{\boldsymbol{u}^* M \boldsymbol{u}} \right)^{1/2}. \tag{9}$$

Здесь M — согласованная матрица массы для невзвешенной нормы $L^2(\Omega)$, а не материальная $M(n)$ из (6). На треугольнике T

$$M_T = \frac{|T|}{12} \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}. \tag{10}$$

Это точная интеграция квадрата модуля P1-поля на данной сетке. Функция потерь — среднее индивидуальных e_M по пакету. Табличные проценты получаются умножением соответствующих статистик индивидуальных ошибок на 100. Среднее ошибок не равно отношению суммарных норм всей выборки. Все результаты сравниваются с дискретным FEM-решением; отдельно точность непрерывной задачи не установлена.

4. SVD-SNO: МОДЫ И ПРЕДСКАЗАНИЕ КОЭФФИЦИЕНТОВ

4.1. Взвешенный POD и выбор ранга

Для каждого вещественного компонента $f \in \{\operatorname{Re} u_s, \operatorname{Im} u_s\}$ обучающие снимки центрируются. Пусть $F_c \in \mathbb{R}^{N_{\mathrm{tr}} \times N_h}$ содержит их по строкам, а $\boldsymbol{m}$ — обучающее среднее. При $W = \operatorname{diag}(M\mathbf{1})$ используется разложение

$$F_c W^{1/2} = U \Sigma V^{\mathsf{T}}, \qquad \Phi_r = W^{-1/2} V_r, \qquad \Phi_r^{\mathsf{T}} W \Phi_r = I. \tag{11}$$

Столбцы Φ_r — пространственные моды в FEM-узлах. Сингулярные значения упорядочивают их вклад в суммарную взвешенную изменчивость train-снимков. Коэффициенты и реконструкция задаются формулами

$$\boldsymbol{c}_W = \Phi_r^{\mathsf{T}} W (\boldsymbol{f} - \boldsymbol{m}), \qquad \boldsymbol{f}_r = \boldsymbol{m} + \Phi_r \boldsymbol{c}_W. \tag{12}$$

Разложение вычисляется рандомизированным алгоритмом [4]: для предела 48 мод берутся десять дополнительных случайных направлений и две степенные итерации с промежуточной QR-ортогонализацией. После проекции на найденное подпространство SVD выполняется для меньшей матрицы. Это способ приближённого построения базиса, а не отдельная обучаемая сеть.

Из рангов до 48 выбирается первый общий ранг Re/Im, для которого средняя валидационная FEM-ошибка реконструкции не превышает 1%. Получено $r = 10$. Для неизменных A, n центрированные матрицы снимков нулевые, поэтому их входные POD-ранги равны нулю. Отсутствующие моды не заменяются численным шумом: меняются только параметры волны.

Для каждой выходной моды сеть предсказывает нормированный коэффициент $\widetilde{c}_j = (c_j - \mu_j)/s_j$, где μ_j, s_j определяются по train. При декодировании сначала возвращаются эти масштабы, затем прибавляется среднее поле. Матрица W используется только в построении и кодировании POD; итоговая ошибка остаётся (9) с согласованной M.

4.2. Сеть версии 2: что означают Z, B и W

Для полноты общий случай имеет $R = \max(r_A, r_n, r)$ модальных позиций. Нормированные коэффициенты материалов дополняются нулями до R, а параметры волны повторяются в каждой строке:

$$C_{j,:} = \big(\mathrm{pad}(\widetilde{\boldsymbol{c}}_A)_j, \mathrm{pad}(\widetilde{\boldsymbol{c}}_n)_j, \cos\theta, \sin\theta, \widetilde{k}\big). \tag{13}$$

В текущем эксперименте $R = r = 10$, и первые два столбца равны нулю. Этот вход описывает параметры волны при заранее зафиксированном материале.

Общий линейный подъём и три остаточных блока имеют вид

$$\begin{aligned} Z^{(0)} &= \sigma(CW_0 + \mathbf{1}b_0^{\mathsf{T}}), \\ Z^{(\ell+1)} &= Z^{(\ell)} + \sigma\Big(Z^{(\ell)}W_{\mathrm{loc}}^{(\ell)} + \mathbf{1}(b_{\mathrm{loc}}^{(\ell)})^{\mathsf{T}} + B^{(\ell)}Z^{(\ell)}W_{\mathrm{ch}}^{(\ell)}\Big), \quad \ell = 0,1,2. \end{aligned} \tag{14}$$

Здесь σ — GELU; $Z^{(\ell)} \in \mathbb{R}^{10\times 24}$ содержит скрытые признаки одного запроса. Строки соответствуют модальным позициям, столбцы — скрытым каналам. Z пересчитывается при изменении k, θ; верхний индекс означает номер слоя.

Матрицы $B^{(\ell)} \in \mathbb{R}^{10\times 10}$ и $W_{\mathrm{loc}}^{(\ell)}, W_{\mathrm{ch}}^{(\ell)} \in \mathbb{R}^{24\times 24}$ — обучаемые веса, фиксированные при предсказании. Умножение справа на W смешивает каналы одной строки, умножение слева на B — модальные позиции одного канала:

$$(ZW)_{j,c} = \sum_d Z_{j,d}W_{d,c}, \qquad (BZ)_{j,c} = \sum_i B_{j,i}Z_{i,c}. \tag{15}$$

Матрица B не является пространственным POD-базисом Φ или FEM-матрицей. Термин «локальная ветвь» означает обработку одной модальной строки; это не локальность в физической области.

Проекция $24 \to 2$ даёт коэффициенты Re и Im, после денормировки

$$\widehat{\boldsymbol{u}} = \boldsymbol{m}_{\mathrm{re}} + \Phi_{\mathrm{re}}\widehat{\boldsymbol{c}}_{\mathrm{re}} + \mathrm{i}\big(\boldsymbol{m}_{\mathrm{im}} + \Phi_{\mathrm{im}}\widehat{\boldsymbol{c}}_{\mathrm{im}}\big). \tag{16}$$

Общее число вещественных параметров равно

$$(5\cdot 24 + 24) + 3(24^2 + 24 + 10^2 + 24^2) + (24\cdot 2 + 2) = 4022.$$

Веса сохраняют `architecture_version=2`; схема приведена на рис. 2.

4.3. Согласованный loss в POD-координатах

Ортогональность (11) относится к W, поэтому реконструкция (12) не обязана минимизировать ошибку в норме M. Для одного компонента определим

$$G = \Phi^{\mathsf{T}}M\Phi, \quad \boldsymbol{c}_* = G^{-1}\Phi^{\mathsf{T}}M(\boldsymbol{f} - \boldsymbol{m}), \quad \boldsymbol{\rho} = \boldsymbol{f} - \boldsymbol{m} - \Phi\boldsymbol{c}_*. \tag{17}$$

Тогда

$$\|\boldsymbol{f} - \boldsymbol{m} - \Phi\widehat{\boldsymbol{c}}\|_M^2 = (\widehat{\boldsymbol{c}} - \boldsymbol{c}_*)^{\mathsf{T}}G(\widehat{\boldsymbol{c}} - \boldsymbol{c}_*) + \|\boldsymbol{\rho}\|_M^2. \tag{18}$$

Сумма выражений Re и Im даёт комплексный числитель (9). Коэффициенты сети предварительно денормируются, а остаток интегрируется напрямую. Поэтому обучение может вычислять ту же FEM-ошибку через малые Gram-матрицы без восстановления всех узлов в каждом пакете. Лишь согласованная проекция с $\boldsymbol{c}_*$ задаёт строгий минимум на том же аффинном пространстве для нормы M.

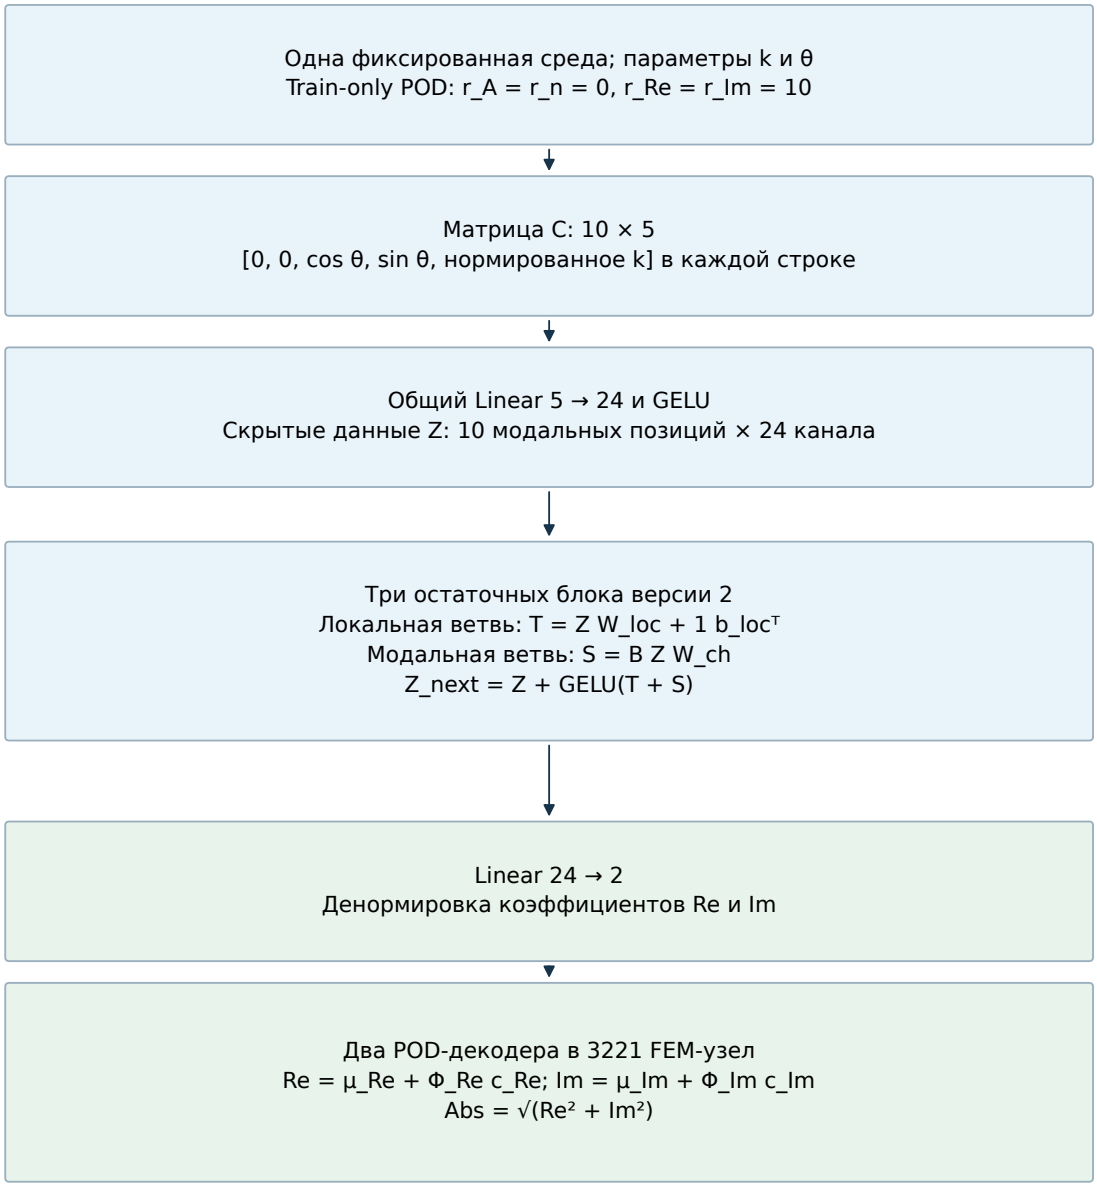


Рис. 2: SVD-SNO версии 2 в текущем статическом примере. Вход содержит параметры волны и два нулевых материальных столбца. Три блока преобразуют модальные признаки; пространственная реконструкция выполняется после предсказания коэффициентов.

5. FNO И CHEBYSHEV-SNO

5.1. FNO: преобразование Фурье и пространственная нелинейность

FNO получает семь каналов $(A, n, \cos\theta, \sin\theta, k, x, y)$ на равномерной сетке 32×32. Материалы и частота нормируются по train, координаты масштабируются в $[-1, 1]$. FEM-поля переносятся на сетку по барицентрическим весам треугольников. Линейный слой даёт 24 скрытых канала; справа и снизу добавляется по восемь нулевых точек.

Каждый из трёх блоков вычисляет

$$v_{\ell+1} = v_\ell + \sigma\big(\mathcal{F}^{-1}\{R_\ell(q)\mathcal{F}v_\ell(q)\} + L_\ell v_\ell + b_\ell\big)\,. \tag{19}$$

L_ℓ — свёртка 1×1, $R_\ell(q)$ — обучаемые комплексные веса спектральной ветви. В rFFT сохраняются восемь положительных и восемь отрицательных позиций первой оси и восемь неотрицательных позиций второй. GELU действует на значения пространственных признаков после обратного FFT [1]. После удаления padding проекция выдаёт два канала; билинейная интерполяция возвращает их в FEM-узлы, затем применяются train-среднее поле и масштабы компонентов.

Padding не навязывает условие (4); сеть обучается граничному поведению по FEM-меткам. Пространственная нелинейность может создавать дополнительные частоты, поэтому FNO не ограничена тем же конечным выходным полиномиальным пространством, что Chebyshev-SNO. В модели 445 010 вещественных степеней свободы: один комплексный вес считается за два. Схема приведена на рис. 3.

5.2. Chebyshev-SNO: тензорный базис и DCT-I

Положим $\xi = x/2$, $\eta = y/2$. Фиксированные пространственные функции равны

$$\psi_{ab}(x, y) = T_a(\xi)T_b(\eta), \qquad T_a(\cos t) = \cos(at). \tag{20}$$

На каждой оси берутся 32 узла Лобатто в возрастающем порядке, $\xi_j = \cos(\pi(1 - j/(m-1)))$, $m = 32$. Для $S_{ja} = T_a(\xi_j)$ и диагональной D с крайними значениями $1/2$ и остальными 1 преобразование DCT-I имеет вид

$$\mathcal{A} = \frac{2}{m-1} DS^{\mathsf{T}}D, \qquad C = \mathcal{A}F\mathcal{A}^{\mathsf{T}}, \qquad F = SCS^{\mathsf{T}}. \tag{21}$$

Последнее равенство точно восстанавливает значения в узлах при сохранении всех мод. Например, при $m = 3$ значения T_2 в узлах $(-1, 0, 1)$ равны $(1, -1, 1)$, а коэффициенты в принятой записи ряда — $(0, 0, 1)$. Этот пример фиксирует нормировку крайних коэффициентов.

В расчёте оставляются 8×8 мод семи входных каналов. Линейный подъём даёт массив $8 \times 8 \times 24$. Три остаточных блока смешивают каналы и последовательно обе модальные оси; затем применяются GELU и остаточное сложение. Проекция в два канала и синтез (21) восстанавливают поля на тензорной сетке. Число параметров равно

$$(7 \cdot 24 + 24) + 3\big(24^2 + 24 + 2 \cdot 8^2\big) + (24 \cdot 2 + 2) = 2426.$$

В отличие от FNO, нелинейность применяется к коэффициентам ряда [2]. В отличие от POD, пространственные функции не выбираются по снимкам решения.

Перенос FEM→Lobatto выполняется барицентрической интерполяцией, обратный перенос — билинейной. DCT-I не применяется к произвольному индексу неструктурированного FEM-узла. Даже при точном преобразовании остаются ошибки интерполяции и усечения. Для фактической матрицы выходного декодера Ψ, включающей обратный перенос в FEM-узлы, можно вычислить оптимальную согласованную проекцию по (17) с заменой Φ на Ψ. Она измеряет ограничение именно используемого аффинного выходного пространства, а не одного непрерывного полиномиального ряда.

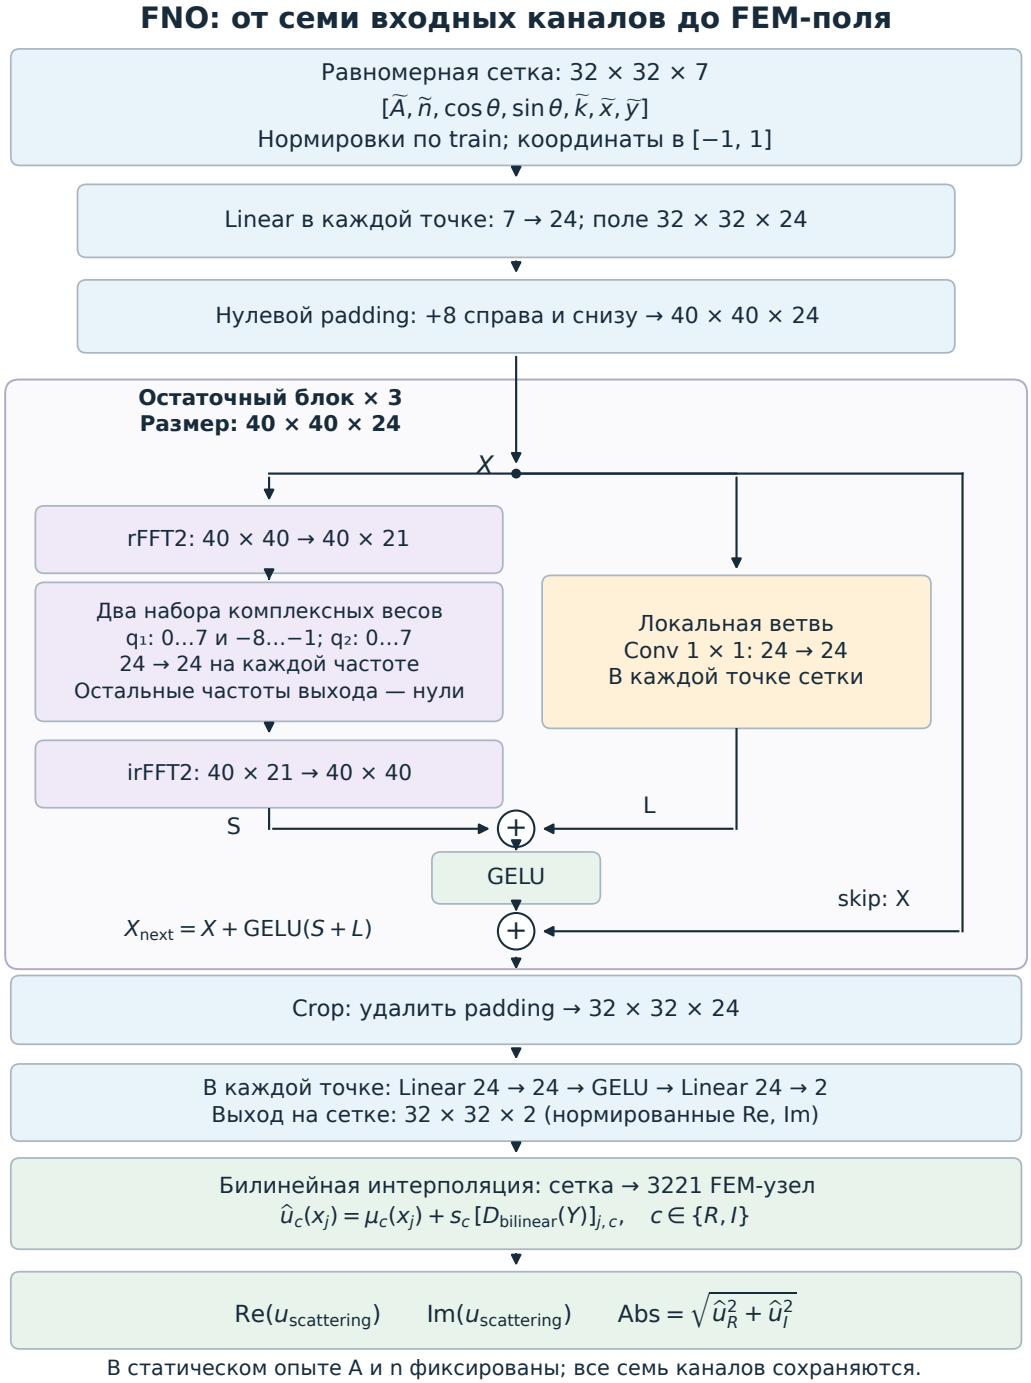


Рис. 3: FNO текущей конфигурации. Спектральная и локальная ветви обрабатывают пространственные признаки. Итоговое поле восстанавливается в исходных FEM-узлах; модуль определяется по Re и Im. Размеры показаны без оси пакета.

6. ПРОТОКОЛ ОБУЧЕНИЯ И РЕЗУЛЬТАТЫ

Для трёх моделей заданы width=24, depth=3, batch=32, seed 42 и максимум 200 эпох. Используется AdamW с шагом 0,002, weight decay 10^{-5} и ограничением глобальной нормы градиента до 1. После каждой эпохи вычисляется средняя validation FEM-ошибка. Итоговое состояние выбирается только по её минимуму; остановка возможна после 50 эпох без улучшения при минимуме 50 эпох. Тест не участвует в выборе состояния сети.

SVD-SNO и Chebyshev-SNO обучены на CPU, существующая FNO — на Apple M4/MPS; сохранённая FNO повторно проверена на CPU. Одинаковые ширина, глубина и предел эпох не задают одинаковую ёмкость или вычислительный бюджет. Времена этих отдельных запусков не используются для вывода об ускорении.

Таблица 3: Текущие модели одной среды: ошибки на 1280 удержанных полях, %; число вещественных параметров

Метод	Параметры	Средняя	Медиана	p95	Максимум
SVD-SNO v2	4 022	0,9475	0,8671	1,6534	2,8962
FNO	445 010	1,6599	1,6329	1,9505	2,2305
Chebyshev-SNO	2 426	7,9364	7,6838	9,8811	11,1065

SVD-SNO выполнила 165 эпох, лучшее состояние получено на эпохе 115; FNO — 142 эпохи с лучшей 92; обе остановлены по validation plateau. Chebyshev-SNO выполнила 200 эпох, лучшее состояние — эпоха 199; достижение лимита не доказывает сходимость.

На тестовых полях оптимальная согласованная POD-проекция даёт среднюю ошибку 0,9188%. Она близка к ошибке SVD-SNO, но вычисляется с использованием истинного поля и не является самостоятельным предсказателем. Для фиксированного Chebyshev-декодера с 8×8 модами средняя оптимальная *валидационная* ошибка равна 7,6143%, p95 — 9,5266%. Поэтому одно изменение весов сети при неизменном декодере не может обеспечить среднюю validation-ошибку 1%. Эта диагностика относится к выбранным модам, сетке и переносу; она не является общим пределом полиномов Чебышёва.

Таблица 3 сравнивает конкретные зафиксированные запуски. Она не устанавливает универсального ранжирования архитектур: различаются число параметров и представления, а разброс по seed не оценивался. Восемь направлений одной частоты зависимы; 1280 полей соответствуют 160 частотным группам. Доверительные интервалы по группам отдельно не рассчитывались.

6.1. Один общий пример поля

Для визуального сравнения используется один и тот же тестовый индекс у всех трёх методов. Выбор выполняется по сохранённому списку test до просмотра ошибок моделей: берётся его первая позиция. Выбран индекс 8: $k = 1{,}001001$, $\theta = 0{,}033124$ рад. Индивидуальные комплексные FEM-ошибки SVD-SNO, FNO и Chebyshev-SNO равны соответственно 1,6985%, 2,1097% и 10,9141%. Точные параметры и ошибки записываются в provenance рисунка. Это конкретный воспроизводимый запрос, а не утверждение о среднем или медианном качестве всей выборки.

На рис. 4–6 показаны действительная часть, мнимая часть и модуль рассеянного поля. Для каждой компоненты FEM и все три предсказания имеют общие цветовые пределы; шкалы абсолютных ошибок также общие между методами. Ошибка модуля $\big||\widehat{u}_s| - |u_s|\big|$ отличается от комплексной ошибки $|\widehat{u}_s - u_s|$, которая лежит в основе (9). Табличные ошибки не заменяются ошибками выбранной картинки.

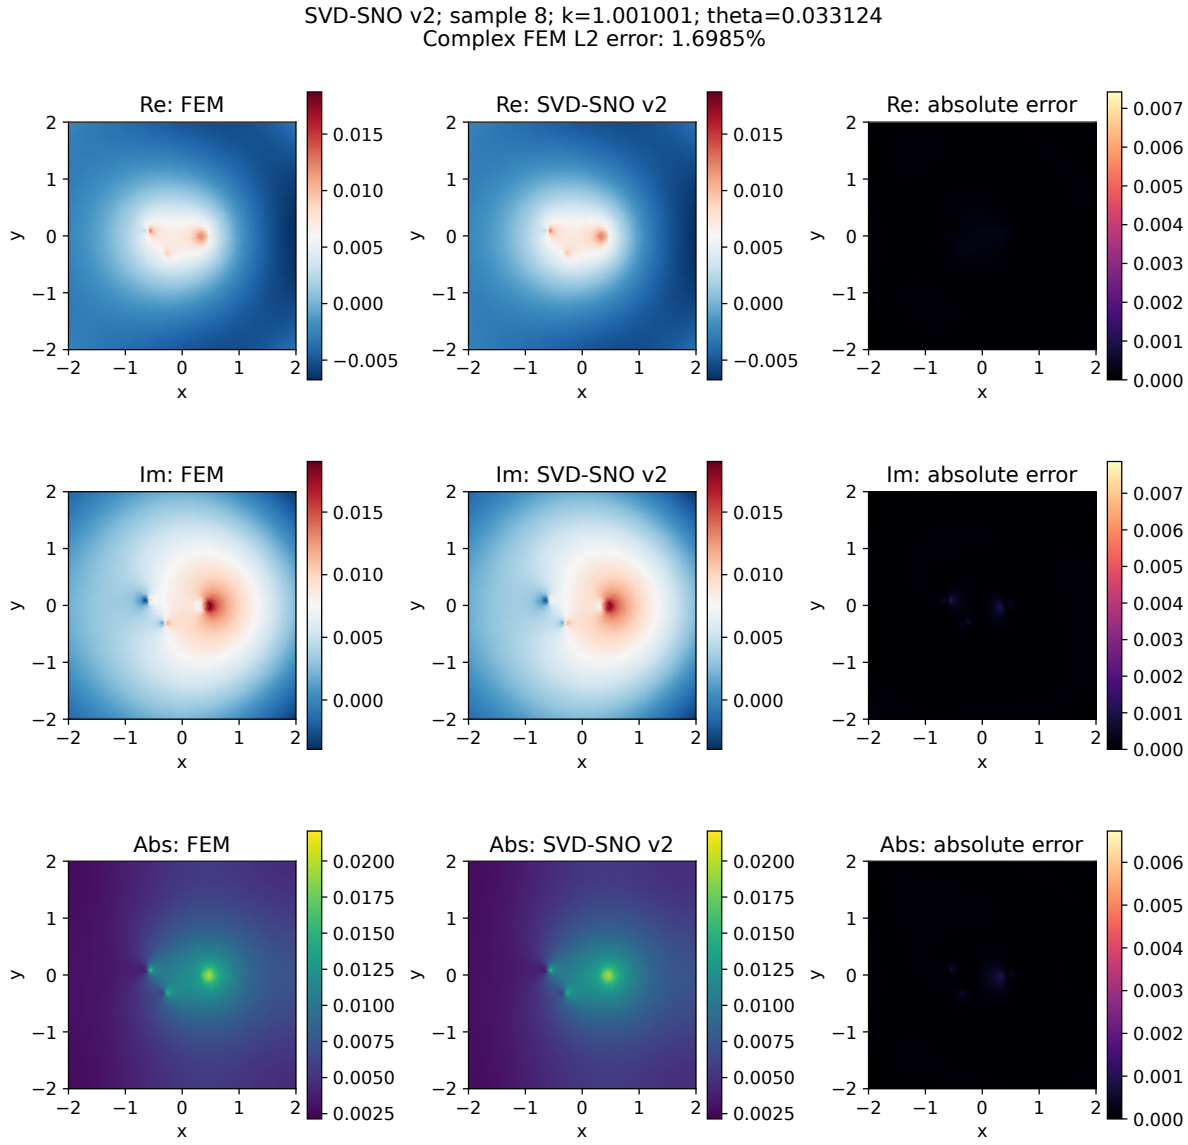


Рис. 4: Один общий тестовый запрос: FEM и SVD-SNO v2. Строки: Re, Im и Abs рассеянного поля; столбцы: FEM, предсказание и абсолютная ошибка компоненты. Индивидуальная комплексная FEM-ошибка указана над полями; шкалы согласованы между тремя моделями.

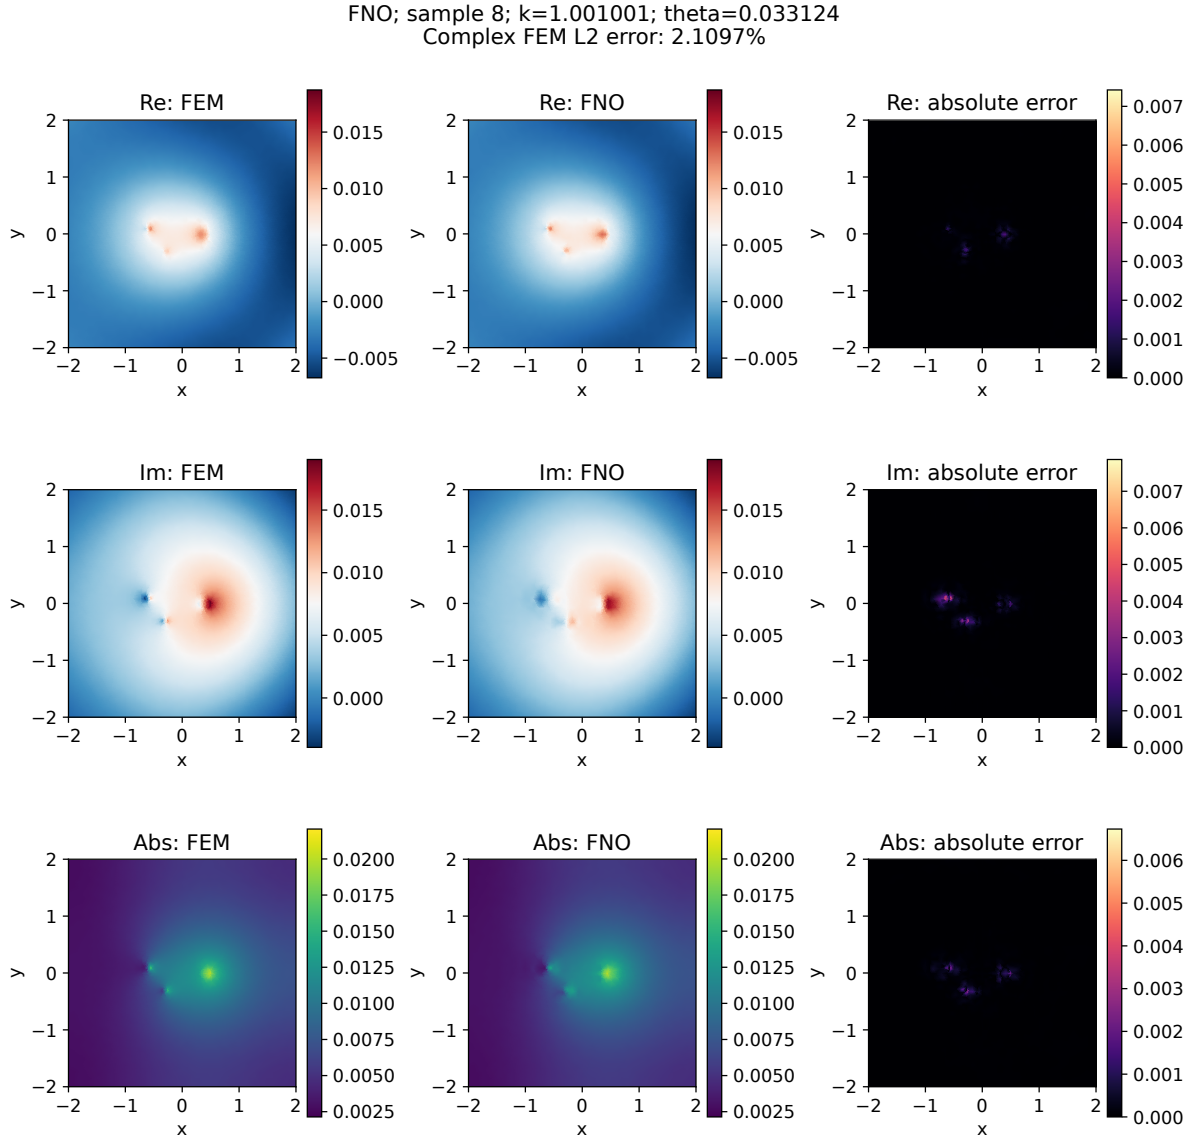


Рис. 5: Один общий тестовый запрос: FEM и FNO. Строки: Re, Im и Abs рассеянного поля; столбцы: FEM, предсказание и абсолютная ошибка компоненты. Индивидуальная комплексная FEM-ошибка указана над полями; шкалы согласованы между тремя моделями.

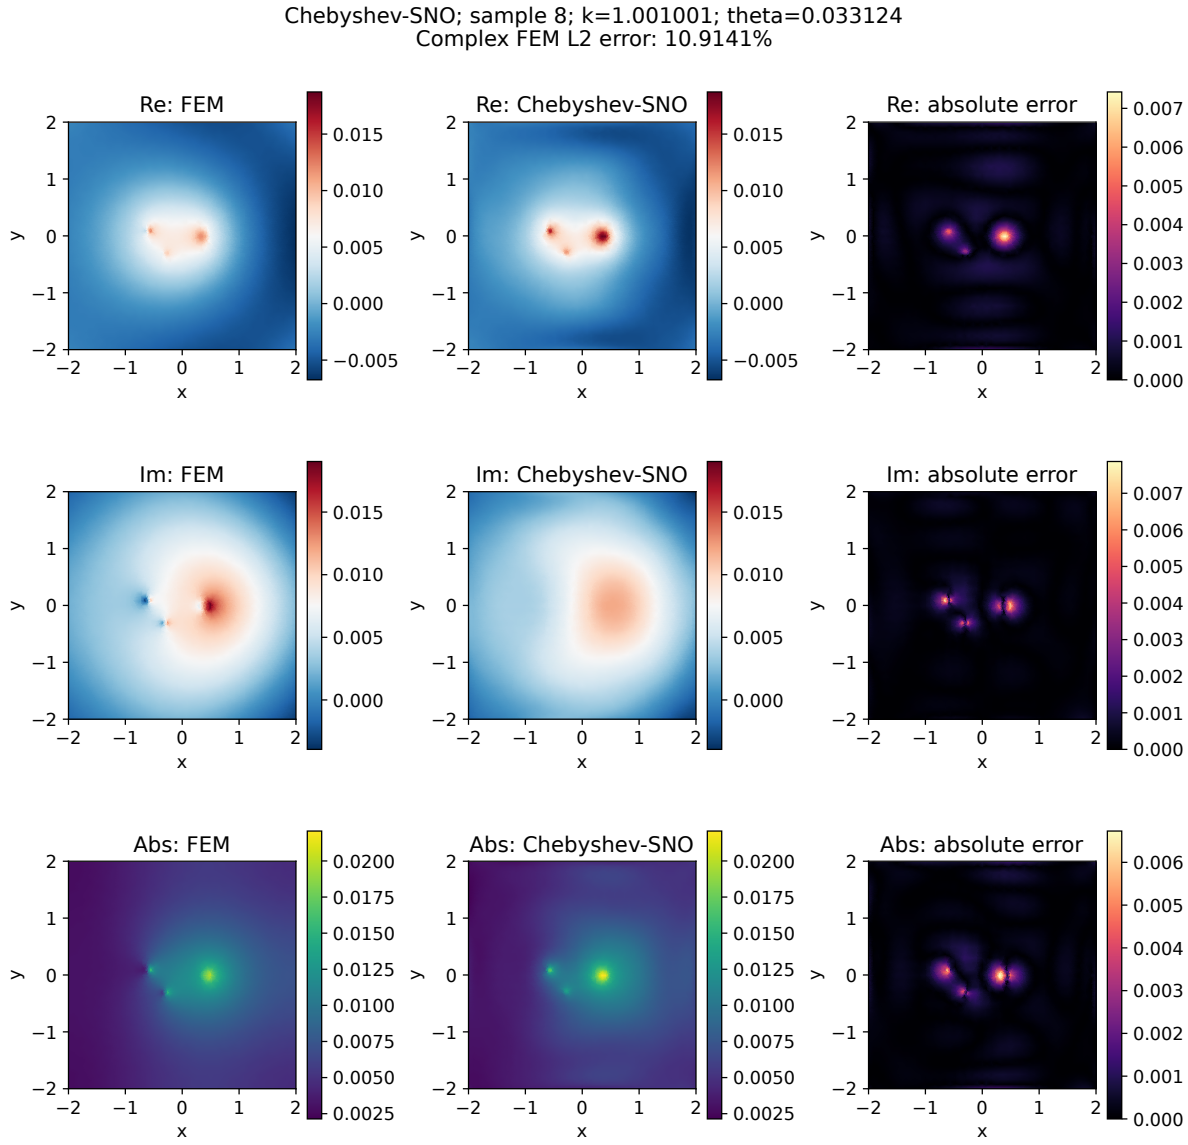


Рис. 6: Один общий тестовый запрос: FEM и Chebyshev-SNO. Строки: Re, Im и Abs рассеянного поля; столбцы: FEM, предсказание и абсолютная ошибка компоненты. Индивидуальная комплексная FEM-ошибка указана над полями; шкалы согласованы между тремя моделями.

6.2. Воспроизводимость

Все результаты относятся к одному набору данных, однозначно заданному fingerprint в сопровождающих метаданных. Сопроводительный файл `REPRODUCIBILITY.md` содержит команды обучения и проверки существующих весов. В `evidence/current_static_low/` сохранены точные конфигурации, метрики, хеши и сведения о трёх выбранных запусках. Скрипт `prepare_predictions.py` проверяет все 1280 test-индексов и ошибок, сверяет предсказание выбранного запроса с повторным инференсом и строит общий пример без обучения и FEM-решений.

`validate_paper.py` проверяет snapshots и численные строки статьи, ссылки на рисунки, LaTeX-метки, DCT-I и число параметров. Версии библиотек сохраняются в метриках; архитектурная версия SVD-SNO — в checkpoint. Независимый новый запуск должен использовать отдельный выходной каталог и сохранять тот же рецепт данных и групповые индексы. Повторение отдельного seed не заменяет исследование устойчивости по нескольким инициализациям.

7. ЗАКЛЮЧЕНИЕ

На одной фиксированной среде сопоставлены три способа предсказания комплексного рассеянного поля. При общем частотном разбиении и согласованной FEM-метрике средние тестовые ошибки составляют 0,9475% для SVD-SNO v2, 1,6599% для FNO и 7,9364% для Chebyshev-SNO. Сохранены полные статистики текущих моделей и точные области применимости этих чисел.

POD адаптирует выходное пространство к обучающим полям, а фиксированное полиномиальное представление позволяет отдельно измерить ограничение фактического декодера. Согласованная проекция и loss с Gram-матрицей связывают эти диагностики с той же FEM-нормой, что используется при оценке. Полученные результаты относятся к удержанным частотам $k \in [1, 2]$, одной сетке и одному seed. Проверка новых материалов, других геометрий и точности непрерывной задачи требует самостоятельного протокола.

ЛИТЕРАТУРА

1. Li Z., Kovachki N., Azizzadenesheli K., Liu B., Bhattacharya K., Stuart A., Anandkumar A. Fourier Neural Operator for Parametric Partial Differential Equations. ICLR. 2021. arXiv:2010.08895v3.
2. Fanaskov V., Oseledets I. Spectral Neural Operators. 2022; версия 2, 2024. arXiv:2205.10573v2.
3. Lu L., Meng X., Cai S., Mao Z., Goswami S., Zhang Z., Karniadakis G. E. A comprehensive and fair comparison of two neural operators (with practical extensions) based on FAIR data. Computer Methods in Applied Mechanics and Engineering. 2022. Vol. 393. Art. 114778. doi:10.1016/j.cma.2022.114778.
4. Halko N., Martinsson P.-G., Tropp J. A. Finding Structure with Randomness: Probabilistic Algorithms for Constructing Approximate Matrix Decompositions. SIAM Review. 2011. Vol. 53, No. 2. P. 217–288. doi:10.1137/090771806.