Приближённое решение двумерной задачи рассеяния на основе POD и нейросетевого отображения коэффициентов

Аннотация. Рассматривается двумерная задача рассеяния плоской волны на проницаемых круговых включениях. Рассеянное поле предсказывается по коэффициентам среды и параметрам волны. Базисы определяются полным сингулярным разложением конечно-элементных снимков, а отображение между коэффициентами аппроксимируется нейросетью с плотным смешиванием мод. Выборка из 8000 полей для 1000 сред разделена по средам в отношении 80:10:10. Для средней валидационной узловой ошибки проекции менее 1% достаточно по 71 моде действительной и мнимой частей поля. По сохранённым результатам запуска длительностью 500 эпох средняя тестовая ошибка сети равна 6,883% в узловой норме и 6,455% в конечно-элементной норме L^2; средняя узловая ошибка SVD-проекции — 0,922%. Их сопоставление характеризует вклад предсказания коэффициентов при фиксированном базисе. Сходимость обучения по достижении предела эпох не установлена. Отдельно показаны статические randomized SVD-SNO для одной фиксированной среды: средняя тестовая FEM-ошибка равна 0,961% при $k \in [1, 2]$ и 5,538% при $k \in [4, 8]$; здесь удерживаются частоты, а не среды.

Ключевые слова: уравнение Гельмгольца; рассеяние волн; метод конечных элементов; POD; сингулярное разложение; нейросетевое приближение.

1. ВВЕДЕНИЕ

При исследовании влияния свойств среды и параметров падающей волны приходится многократно решать задачу рассеяния. Предварительно рассчитанные данные позволяют обучить приближённое отображение от параметров задачи к решению. Нейрооператорные методы развивают этот подход для отображений между функциональными пространствами [1]; спектральные нейрооператоры представляют входные и выходные функции через коэффициенты разложений [2].

В настоящей работе базисы определяются по конечно-элементным снимкам посредством сингулярного разложения (SVD). Их усечение задаёт POD-представление (proper orthogonal decomposition). Нейросеть отображает коэффициенты среды и параметры волны в коэффициенты рассеянного поля. Это позволяет отделить ошибку пространственного представления от ошибки предсказания коэффициентов.

Цель работы — построить редуцированную модель для семейства неоднородных сред и оценить её на отложенных средах. Рассматривается фиксированная сетка с 24 допустимыми положениями включений. Сеть далее обозначается SVD-SNO; это название отражает связь со спектральным подходом, но не предполагает тождества архитектуре [2] или доказанного переноса между сетками. Исследуются выбор ранга, согласование функции потерь с нормой поля и различие ошибок сети и проекции.

2. ПОСТАНОВКА ЗАДАЧИ И ДИСКРЕТИЗАЦИЯ

Пусть $\Omega = (-2, 2)^2 \subset \mathbb{R}^2$. Падающая плоская волна имеет вид

$$u_i(\boldsymbol{x}) = \exp(\mathrm{i}k\boldsymbol{d} \cdot \boldsymbol{x}), \qquad \boldsymbol{d} = (\cos\theta, \sin\theta), \quad k > 0. \tag{1}$$

Коэффициенты $A(\boldsymbol{x}) > 0$ и $n(\boldsymbol{x}) > 0$ — вещественные скалярные кусочно-постоянные функции. Вне включений они равны единице. Полное поле $u = u_i + u_s$ удовлетворяет уравнению $\nabla \cdot (A\nabla u) + k^2 n u = 0$. Поэтому для рассеянного поля получаем

$$\nabla \cdot (A\nabla u_s) + k^2 n u_s = \nabla \cdot \big((1 - A)\nabla u_i\big) + k^2(1 - n)u_i, \quad \boldsymbol{x} \in \Omega. \tag{2}$$

При разрывных коэффициентах равенство (2) понимается в слабом смысле. Это учитывает вклад границ раздела материалов; замена его правой части только объёмным выражением внутри каждого материала не была бы эквивалентной постановкой.

На внешней границе задаётся локальное поглощающее условие первого порядка

$$A\,\partial_\nu u_s - \mathrm{i}k u_s = 0, \qquad \boldsymbol{x} \in \partial\Omega, \tag{3}$$

где ν — внешняя единичная нормаль. Все включения расположены строго внутри области; в окрестности $\partial\Omega$ имеем $A = n = 1$. Условие (3) приближает излучение на конечной границе. Ниже оценивается приближение решения этой ограниченной задачи; погрешность замены внешней задачи отдельно не исследуется.

Каждая среда получается активацией от 3 до 10 кругов из фиксированного набора $D_1, \ldots, D_{24}$, показанного на рис. 1. Внутри каждого активного круга независимо выбираются значения

$$0{,}6 \leqslant A_j \leqslant 0{,}9, \qquad 1{,}5 \leqslant n_j \leqslant 3, \qquad 1 \leqslant k \leqslant 2. \tag{4}$$

Материальные коэффициенты имеют логарифмически равномерные распределения в указанных диапазонах. Число активных кругов выбирается равновероятно из целых чисел от 3 до 10, а набор кругов — без повторений. Волновое число выбирается равномерно для каждой среды и сохраняется при смене направления падающей волны.

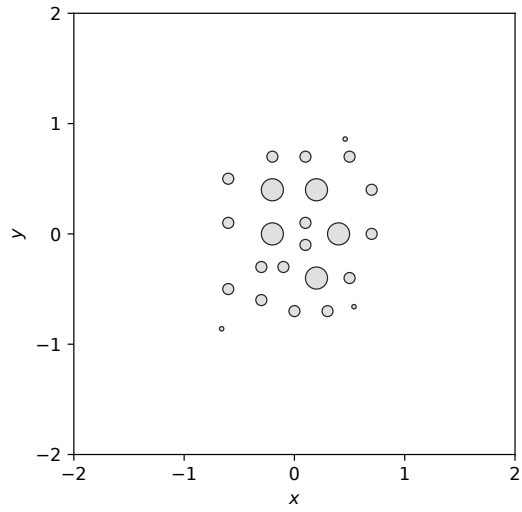


Рис. 1: Расчётная область и 24 допустимых круговых включения. В отдельной среде активны от 3 до 10 кругов; остальные заполнены фоновым материалом.

Общая неструктурированная треугольная сетка согласована с границами всех допустимых кругов. Коэффициенты среды задаются поэлементно. Пусть $V_h \subset H^1(\Omega;\mathbb{C})$ — пространство непрерывных кусочно-линейных функций. С учётом (3) слабая задача имеет вид: найти $u_{s,h} \in V_h$, такое, что для любого $v_h \in V_h$

$$\begin{aligned} \int_\Omega A\nabla u_{s,h}\cdot\nabla\overline{v_h}\,d\boldsymbol{x} - k^2\int_\Omega n u_{s,h}\overline{v_h}\,d\boldsymbol{x} - \mathrm{i}k\int_{\partial\Omega} u_{s,h}\overline{v_h}\,ds \\ = -\int_\Omega (A-1)\nabla u_i\cdot\nabla\overline{v_h}\,d\boldsymbol{x} + k^2\int_\Omega (n-1)u_i\overline{v_h}\,d\boldsymbol{x}. \end{aligned} \tag{5}$$

Знаки правой части следуют из интегрирования (2) по частям; граничный член от контраста коэффициентов равен нулю. Дискретная система имеет вид

$$\big(K(A) - k^2 M(n) - \mathrm{i}k M_{\partial\Omega}\big)\boldsymbol{u}_s = \boldsymbol{b}(A, n, k, \theta) \tag{6}$$

и решается прямым методом LU. Здесь $K(A)$, $M(n)$ и $M_{\partial\Omega}$ — матрицы жёсткости, взвешенной массы и граничной массы соответственно.

Целевой фоновый шаг сетки равен 4/96; сетка содержит $N_h = 11\,380$ узлов и 22 374 треугольника. Для нейросетевого представления значения A и n усредняются в каждом узле по прилегающим элементам с одинаковыми весами. Конечно-элементные решения вычисляются с исходными поэлементными коэффициентами, поэтому это усреднение влияет только на входное представление модели.

3. POD-ПРЕДСТАВЛЕНИЕ И ВЫБОР РАНГА

3.1. Как сингулярное разложение выделяет пространственные моды

Пусть $\boldsymbol{f}^{(s)} \in \mathbb{R}^{N_h}$, $s = 1, \ldots, N_f$, — обучающие снимки одного вещественного поля. Определим среднее и матрицу центрированных снимков:

$$\boldsymbol{m}_f = \frac{1}{N_f} \sum_{s=1}^{N_f} \boldsymbol{f}^{(s)}, \qquad F_c = \begin{bmatrix} (\boldsymbol{f}^{(1)} - \boldsymbol{m}_f)^{\mathsf{T}} \\ \vdots \\ (\boldsymbol{f}^{(N_f)} - \boldsymbol{m}_f)^{\mathsf{T}} \end{bmatrix} = U \Sigma V^{\mathsf{T}}. \tag{7}$$

Пусть $p = \min(N_f, N_h)$. В экономном разложении $U \in \mathbb{R}^{N_f \times p}$, $V \in \mathbb{R}^{N_h \times p}$, а $\Sigma = \operatorname{diag}(\sigma_1, \ldots, \sigma_p)$, где $\sigma_1 \geqslant \cdots \geqslant \sigma_p \geqslant 0$. Столбец $\boldsymbol{v}_j$ матрицы V задаёт пространственный рисунок на узлах сетки; столбец $\boldsymbol{u}_j$ матрицы U показывает, с какими весами этот рисунок входит в разные снимки. Таким образом,

$$F_c = \sum_{j=1}^{p} \sigma_j \boldsymbol{u}_j \boldsymbol{v}_j^{\mathsf{T}}, \qquad \boldsymbol{f}^{(s)} = \boldsymbol{m}_f + \sum_{j=1}^{p} \sigma_j U_{sj} \boldsymbol{v}_j. \tag{8}$$

Сингулярное значение измеряет вклад моды в суммарную квадратичную изменчивость обучающих снимков. POD оставляет ведущие пространственные рисунки и заменяет узловой вектор коротким вектором их весов. Это линейное сжатие данных; сама по себе процедура SVD не предсказывает решение по параметрам среды.

В основном эксперименте используется полный экономный SVD с последующим усечением. Первые r правых сингулярных векторов образуют матрицу $\Phi_{f,r} \in \mathbb{R}^{N_h \times r}$, для которой $\Phi_{f,r}^{\mathsf{T}} \Phi_{f,r} = I_r$. Кодирование и восстановление задаются формулами

$$\boldsymbol{c}_f = \Phi_{f,r}^{\mathsf{T}} (\boldsymbol{f} - \boldsymbol{m}_f), \qquad \boldsymbol{f}_r = \boldsymbol{m}_f + \Phi_{f,r} \boldsymbol{c}_f. \tag{9}$$

Для обучающей матрицы коэффициентов $C_f = F_c \Phi_{f,r} = U_r \Sigma_r$. Усечённое SVD оптимально приближает центрированную обучающую матрицу в норме Фробениуса; это свойство не гарантирует точность на новых средах или оптимальность в другой норме. Доля сохранённой квадратичной изменчивости и остаток обучающей матрицы равны

$$E_r = \frac{\sum_{j=1}^{r} \sigma_j^2}{\sum_{j=1}^{p} \sigma_j^2}, \qquad \|F_c - U_r \Sigma_r V_r^{\mathsf{T}}\|_F^2 = \sum_{j=r+1}^{p} \sigma_j^2. \tag{10}$$

Здесь E_r определено при ненулевой центрированной матрице. Высокое значение E_r служит диагностикой сжатия обучающих данных; в работе ранг выбирается непосредственно по ошибке восстановления валидационных полей.

3.2. Отдельные базисы и валидационный выбор ранга

Отдельные базисы строятся для A, n, $\operatorname{Re} u_s$ и $\operatorname{Im} u_s$. Для коэффициентов среды берётся по одному снимку на обучающую среду, для решения — все её направления. Средние поля и базисы вычисляются только по обучающей выборке.

Далее $\boldsymbol{u}^{(s)} \in \mathbb{C}^{N_h}$ обозначает узловой вектор рассеянного поля. При одинаковом числе r мод для обеих частей его проекция равна

$$\boldsymbol{u}_r^{(s)} = \boldsymbol{m}_{\mathrm{re}} + \Phi_{\mathrm{re},r}\boldsymbol{c}_{\mathrm{re}}^{(s)} + \mathrm{i}\big(\boldsymbol{m}_{\mathrm{im}} + \Phi_{\mathrm{im},r}\boldsymbol{c}_{\mathrm{im}}^{(s)}\big). \tag{11}$$

Общий ранг решения выбирается по валидационной выборке из предварительно вычисленных первых 136 мод:

$$R = \min\left\{ r \in \{1,\dots,136\} : \quad \frac{1}{N_{\mathrm{val}}} \sum_{s\in\mathcal{I}_{\mathrm{val}}} \frac{\|\boldsymbol{u}^{(s)} - \boldsymbol{u}_r^{(s)}\|_2}{\|\boldsymbol{u}^{(s)}\|_2} \leqslant \varepsilon_{\mathrm{POD}} \right\}. \tag{12}$$

Для $\varepsilon_{\mathrm{POD}} = 10^{-2}$ получено $R = 71$. Средняя валидационная узловая ошибка проекции составляет 0,9696%, 95-й процентиль — 2,3105%. Таким образом, допуск относится к средней ошибке, а не к каждому полю. Тестовые ошибки не входят в критерий (12).

При фиксированных кругах поэлементные поля имеют вид

$$A = 1 + \sum_{j=1}^{24} a_j \chi_{D_j}, \qquad n = 1 + \sum_{j=1}^{24} b_j \chi_{D_j},$$

где $a_j = b_j = 0$ для неактивного включения. Усреднение по узлам является линейным, поэтому размерность пространства центрированных входных снимков не превышает 24. В расчёте оба входных численных ранга равны 24. Компоненты, для которых сингулярное значение не превышает 10^{-5} от наибольшего значения соответствующего входного поля, зануляются.

Для каждой компоненты применяется нормировка

$$\widetilde{c}_{f,j} = (c_{f,j} - \mu_{f,j})/s_{f,j}, \qquad \widetilde{k} = (k - \mu_k)/s_k, \tag{13}$$

где средние и масштабы оцениваются по обучающей выборке. Обозначим исходное стандартное отклонение модальных коэффициентов через $\sigma_{f,j}$. Масштаб $s_{f,j}$ равен $\sigma_{f,j}$, если оно превышает $\max(10^{-6}\max_j \sigma_{f,j}, 10^{-12})$; иначе используется единица. Это исключает усиление численного шума в неактивных входных компонентах. При нормировке k к стандартному отклонению добавляется 10^{-8}.

3.3. Чем рандомизированный SVD отличается от полного

Полный экономный SVD раскладывает всю матрицу F_c, после чего сохраняются нужные столбцы. Рандомизированный вариант [3] сначала приближённо находит её ведущее подпространство. Для требуемого числа r_0 мод генерируется случайная матрица $\Omega \in \mathbb{R}^{N_h\times(r_0+p_0)}$, где p_0 — число дополнительных векторов. Затем вычисляются

$$Y = F_c\Omega, \quad Q = \operatorname{orth}(Y), \quad H = Q^{\mathsf{T}}F_c = \widetilde{U}\widetilde{\Sigma}\widetilde{V}^{\mathsf{T}}. \tag{14}$$

Первые r_0 столбцов $\widetilde{V}$ используются как приближённые пространственные моды. При степенных итерациях образ Y уточняется умножениями на F_c^{T} и F_c с промежуточной QR-ортогонализацией; это усиливает вклад ведущих сингулярных направлений. В сохранённой диагностике $r_0 = 136$, $p_0 = 10$, выполнены две такие итерации. Оба варианта меняют способ построения POD-базиса, но не принцип дальнейшего нейросетевого предсказания коэффициентов. Основные результаты ниже относятся к полному SVD.

4. НЕЙРОСЕТЕВОЕ ОТОБРАЖЕНИЕ КОЭФФИЦИЕНТОВ

4.1. Роль SNO в вычислительной цепочке

Приближается отображение $(A, n, \theta, k) \mapsto u_s$. В SVD-SNO оно разбито на три этапа: кодирование полей среды в POD-коэффициенты, обучаемое нелинейное отображение коэффициентов и декодирование выходных коэффициентов в поле. Базисы фиксируются до обучения сети. При новом запросе истинные коэффициенты решения неизвестны: именно их предсказывает сеть по входным данным. FEM-решатель нужен для создания обучающих меток, а не для вычисления каждого нового предсказания.

Название SNO связано с работой [2], где отображение строится между коэффициентами рядов Фурье или Чебышёва и нелинейности применяются в пространстве коэффициентов. Здесь вместо заранее заданных рядов используются POD-моды, найденные по данным. Их номер упорядочен по сингулярным значениям и не является волновым числом Фурье. Поэтому свойства исходного SNO нельзя автоматически переносить на данную модель.

4.2. Архитектура исследованной сети

Формулы этого подраздела описывают JAX-реализацию сохранённого эксперимента, для которого далее приведены численные результаты. Для каждого $j = 1, \ldots, R$ формируется строка входной матрицы $X \in \mathbb{R}^{R\times 5}$:

$$X_{j,:} = \left(\widetilde{c}_{A,j}, \widetilde{c}_{n,j}, \cos\theta, \sin\theta, \widetilde{k}\right). \tag{15}$$

Входные векторы коэффициентов длины 24 дополняются нулями до $R = 71$. Параметры волны повторяются в каждой строке. Индекс j обозначает номер POD-моды соответствующего поля; моды разных полей построены независимо.

Чтобы читать формулу блока, следует различать передаваемые данные и обучаемые параметры. Матрица $Z^{(\ell)}$ — скрытое состояние для *одного* входного примера после ℓ-го блока. Верхний индекс обозначает номер слоя, а не степень. Строка j соответствует позиции моды, столбец c — скрытому каналу признаков. Например, $Z^{(\ell)}_{j,c}$ является одним числом, вычисленным сетью для текущей среды и волны. Сами скрытые каналы не отождествляются с A, n, Re или Im: их представление формируется при обучении.

Матрицы $B^{(\ell)}$ и $W^{(\ell)}$, напротив, являются весами сети: они изменяются оптимизатором на этапе обучения и фиксируются при предсказании. Для разных слоёв используются разные веса; для всех примеров в одном слое — одни и те же. Их назначение суммировано в табл. 1.

Таблица 1: Данные и параметры исторической SVD-SNO при $R = 71$, ширине $w = 64$

Обозначение	Размер	Смысл
$Z^{(\ell)}$	71×64	Скрытые признаки; вычисляются заново для каждого запроса.
$B^{(\ell)}$	71×71	Обучаемые веса обмена между строками, то есть позициями мод.
$W^{(\ell)}_{\mathrm{loc}}$, $W^{(\ell)}_{\mathrm{ch}}$	64×64	Обучаемые веса смешивания скрытых каналов.
$\Phi_{f,R}$	$N_h \times 71$	Пространственные POD-моды; найдены по снимкам до обучения сети.

Таким образом, B не является POD-базисом: базис обозначается через Φ и связывает коэффициенты с физическими узлами. Также B не является матрицей конечных элементов. Для пакета примеров к Z добавляется первая ось пакета, то есть в коде хранится массив

$[N_{\text{batch}}, R, w]$; далее эта ось опущена, поскольку одинаковые операции выполняются независимо для каждого примера.

Начальное преобразование и четыре остаточных блока имеют вид

$$\begin{aligned} Z^{(0)} &= \sigma\big(XW_0 + \mathbf{1}b_0^{\mathsf{T}}\big), \\ Z^{(\ell+1)} &= Z^{(\ell)} + \sigma\big(Z^{(\ell)}W_{\text{loc}}^{(\ell)} + \mathbf{1}(b_{\text{loc}}^{(\ell)})^{\mathsf{T}} \\ &\qquad + B^{(\ell)}Z^{(\ell)}W_{\text{ch}}^{(\ell)} + \mathbf{1}(b_{\text{ch}}^{(\ell)})^{\mathsf{T}}\big), \quad \ell = 0, \dots, 3, \end{aligned} \tag{16}$$

где σ — GELU, $Z^{(\ell)} \in \mathbb{R}^{R\times 64}$, $B^{(\ell)} \in \mathbb{R}^{R\times R}$, $W_{\text{loc}}^{(\ell)}, W_{\text{ch}}^{(\ell)} \in \mathbb{R}^{64\times 64}$. Вектор $\mathbf{1} \in \mathbb{R}^R$ обеспечивает одинаковый сдвиг во всех строках. Матрица $B^{(\ell)}$ смешивает моды, а матрицы $W^{(\ell)}$ — каналы. Выходная линейная проекция

$$\widehat{\widetilde{C}} = Z^{(4)}W_{\text{out}} + \mathbf{1}b_{\text{out}}^{\mathsf{T}} \in \mathbb{R}^{R\times 2}$$

даёт нормированные коэффициенты действительной и мнимой частей. При указанных размерах сеть содержит 53 958 обучаемых вещественных параметров.

Направления смешивания можно проверить по отдельным элементам:

$$(ZW)_{j,c} = \sum_{d=1}^{w} Z_{j,d}W_{d,c}, \qquad (BZ)_{j,c} = \sum_{i=1}^{R} B_{j,i}Z_{i,c}. \tag{17}$$

Умножение *справа* на W смешивает столбцы одной строки: признаки различных каналов одной модальной позиции. Умножение *слева* на B смешивает строки одного столбца: признаки одного канала из разных модальных позиций. Форма массива $R \times w$ при этих операциях сохраняется. Числовой пример на рис. 2 использует $R = 3$, $w = 2$ только для наглядности; это не размеры обученной сети. Векторы b в формуле блока являются обучаемыми сдвигами, одинаково добавляемыми ко всем строкам.

Входное преобразование увеличивает число каналов с 5 до 64, чтобы сеть могла хранить несколько скрытых признаков для каждой моды. Локальная ветвь ZW_{loc} преобразует каналы одной строки без обмена между модами; произведение BZW_{ch} обеспечивает обмен между всеми строками и каналами. Здесь слово «локальная» относится к номеру моды, а не к точке физической области. Нелинейность GELU позволяет описывать нелинейную зависимость решения от среды, а остаточное сложение сохраняет вход блока и обучает его поправку. Последняя проекция $64 \to 2$ выдаёт два вещественных коэффициента для каждой выходной моды. Дополнительные пространственные координаты в сеть этой реализации не подаются: геометрия узлов содержится в сохранённых базисах.

Число параметров можно проверить непосредственно по размерам матриц: входное преобразование содержит $5 \cdot 64 + 64 = 384$ параметра; каждый блок — $71^2 + 2(64^2 + 64) = 13\,361$; выходная проекция — $64 \cdot 2 + 2 = 130$. Всего $384 + 4 \cdot 13\,361 + 130 = 53\,958$.

После обратной нормировки восстанавливается поле

$$\widehat{\boldsymbol{u}} = \boldsymbol{m}_{\text{re}} + \Phi_{\text{re},R}\widehat{\boldsymbol{c}}_{\text{re}} + \mathrm{i}\big(\boldsymbol{m}_{\text{im}} + \Phi_{\text{im},R}\widehat{\boldsymbol{c}}_{\text{im}}\big). \tag{18}$$

Для нового запроса используются сохранённые средние, базисы, нормировки и веса сети. При измерении стоимости предсказания необходимо учитывать кодирование входа и реконструкцию (18).



Рис. 2: Как читать Z, W и B. Строки Z — позиции мод, столбцы — скрытые каналы; Z зависит от входного примера. Обучаемая матрица W смешивает каналы, а B — модальные позиции. На условных числах отдельно показаны операции ZW и BZ, ниже — порядок обработки текущего PyTorch-блока. Это арифметическая иллюстрация, а не результаты обучения.

4.3. Результат: действительная часть, мнимая часть и модуль

Искомое поле является комплексным. Для SNO и FNO единый физический результат представляется тремя вещественными полями:

$$\begin{aligned} \widehat{u}_{\mathrm{re}}(\boldsymbol{x}) &= \operatorname{Re}\widehat{u}_s(\boldsymbol{x}), \\ \widehat{u}_{\mathrm{im}}(\boldsymbol{x}) &= \operatorname{Im}\widehat{u}_s(\boldsymbol{x}), \\ \widehat{u}_{\mathrm{abs}}(\boldsymbol{x}) &= |\widehat{u}_s(\boldsymbol{x})| = \sqrt{\widehat{u}_{\mathrm{re}}(\boldsymbol{x})^2 + \widehat{u}_{\mathrm{im}}(\boldsymbol{x})^2}. \end{aligned} \tag{19}$$

Здесь $u_s \equiv u_{\mathrm{scattering}}$; во всех трёх случаях рассматривается рассеянное поле. В SVD-SNO первые два поля восстанавливаются по формуле (18). Модуль вычисляется после обратной нормировки и пространственной реконструкции; модуль модальных коэффициентов не даёт модуль поля. Отдельный независимый выход сети для модуля не требуется, поскольку третье поле однозначно определяется первыми двумя. Поэтому сохраняются два обучаемых выходных канала и согласованность трёх представлений.

При визуальном сравнении для каждого представления следует показывать FEM-поле, предсказание и абсолютную ошибку соответствующего поля. При этом $\big||\widehat{u}_s| - |u_s|\big|$ характеризует ошибку амплитуды и отличается от комплексной ошибки $|\widehat{u}_s - u_s|$, учитывающей также фазу. Числа в таблице результатов ниже относятся к комплексному полю, а не к отдельно измеренным ошибкам трёх изображений.

4.4. Связь с текущей реализацией и отличие от FNO

В текущем модуле репозитория `neural_operator/sno/model.py` реализован иной вариант SVD-SNO. Независимые коэффициенты A и n и три параметра волны объединяются в один вектор; общий линейный слой переводит его в массив размера $R \times w$. Затем каждый остаточный блок последовательно смешивает каналы и моды, после чего применяет GELU и добавляет вход блока. При тех же направлениях умножения это записывается как

$$Z^{(\ell+1)} = Z^{(\ell)} + \sigma\Big(B^{(\ell)}\big(Z^{(\ell)}W^{(\ell)} + \mathbf{1}(b^{(\ell)})^{\mathsf{T}}\big)\Big). \tag{20}$$

Сдвиг здесь добавляется *до* смешивания мод. Отдельной локальной ветви из (16) у этого варианта нет; начальное преобразование также не содержит GELU. Проекция в два канала и POD-декодирование сохраняются. Поэтому число 53 958 и приведённые далее ошибки основного эксперимента относятся к описанному JAX-запуску, а не автоматически к текущему PyTorch-модулю.

В FNO [1] скрытые признаки хранятся на регулярной пространственной сетке. Спектральная ветвь блока выполняет FFT, умножает сохранённые низкочастотные коэффициенты на обучаемые матрицы и возвращает результат обратным FFT. В текущей реализации эта ветвь суммируется с преобразованием каналов в каждой точке, затем применяются GELU и остаточное сложение. Таким образом, FNO возвращается в физическое пространство внутри каждого блока, а SVD-SNO смешивает POD-коэффициенты и декодирует поле в конце. Выход FNO также содержит два вещественных канала; после декодирования на FEM-узлы модуль вычисляется по (19). Результаты FNO не входят в таблицу исторического JAX-эксперимента 3.

На рис. 4 показана текущая конфигурация FNO для статических наборов: сетка 32×32, семь каналов, ширина 24, три блока и нулевое дополнение справа и снизу на восемь точек. Вход содержит нормированные A, n, k, $\cos\theta, \sin\theta$ и координаты из $[-1, 1]$. После удаления дополнения и проекции в два канала выполняется билинейная интерполяция в FEM-узлы, затем обратная нормировка. Постоянство материала не удаляет каналы A, n из FNO.

На рис. 3 показан весь путь от исходных данных до трёх представлений рассеянного поля. Две панели разделяют архитектуру сохранённого JAX-эксперимента и текущий PyTorch-вариант; общие названия этапов не означают совпадения блоков или обученных весов. На схеме q — общий входной вектор текущего варианта длины $d = r_A + r_n + 3$, $H = w$ — ширина скрытого слоя, L — число остаточных блоков.

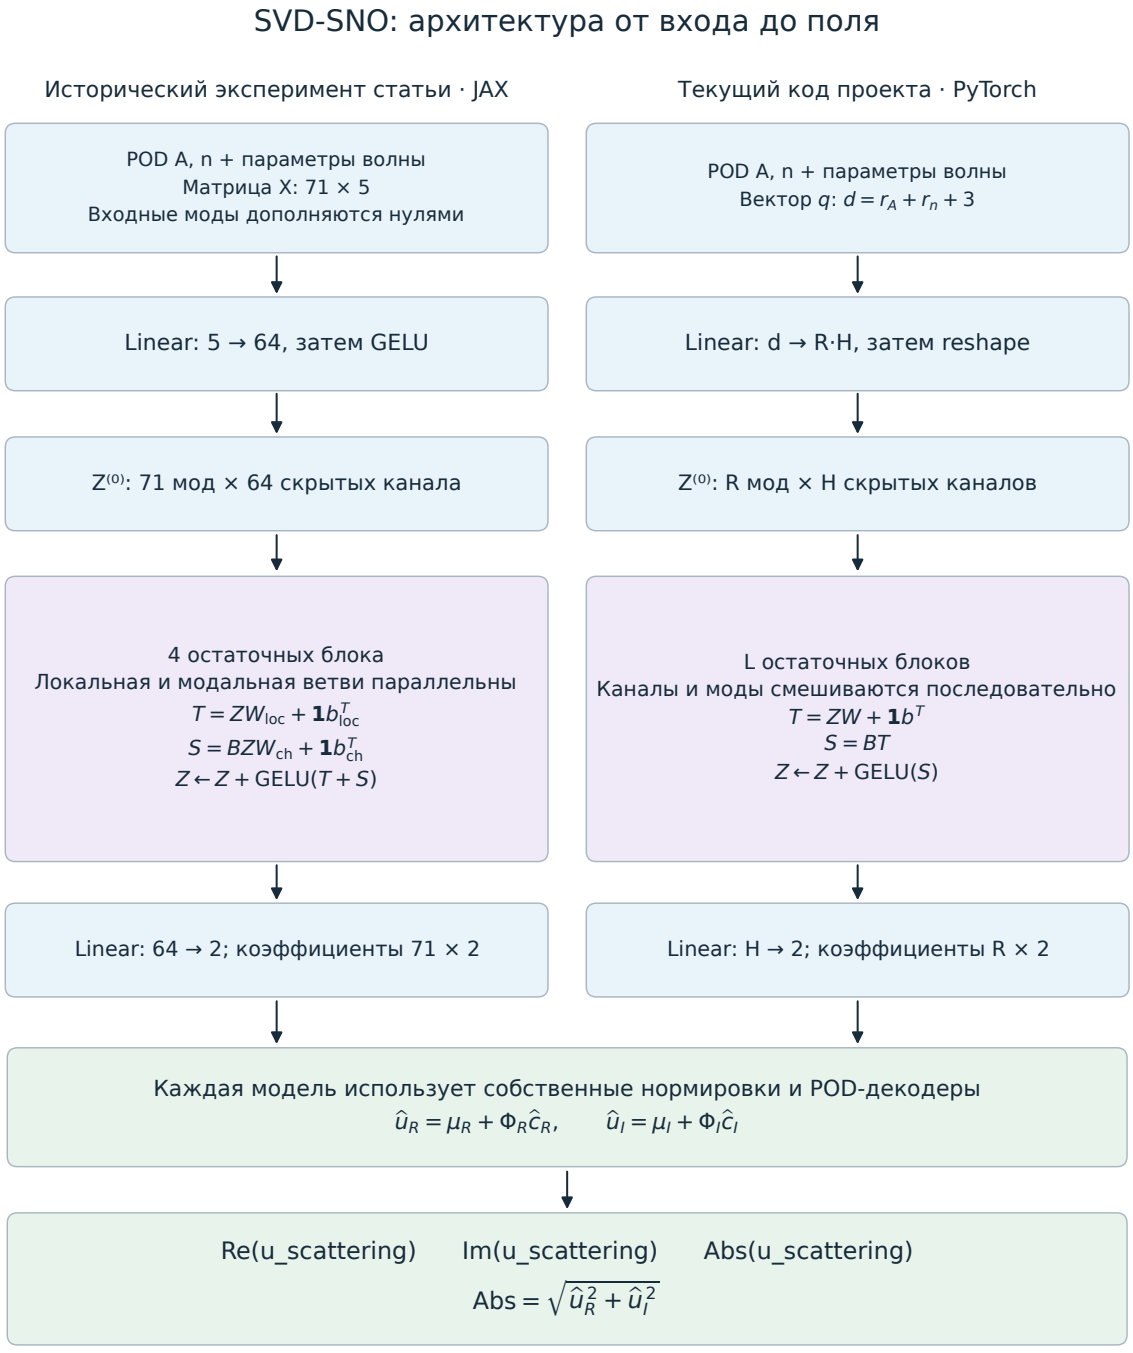


Рис. 3: Архитектура SVD-SNO. Левая панель описывает историческую JAX-сеть: матрица входа $R \times 5$, начальная GELU и четыре блока с локальной и межмодовой ветвями. Правая панель описывает текущую PyTorch-сеть: единый вектор входных признаков, общий линейный подъём и последовательное смешивание каналов и мод. В обоих случаях предсказываются коэффициенты Re и Im, затем поле восстанавливается в POD-базисах и вычисляется Abs. Числа основной таблицы относятся к левой панели.

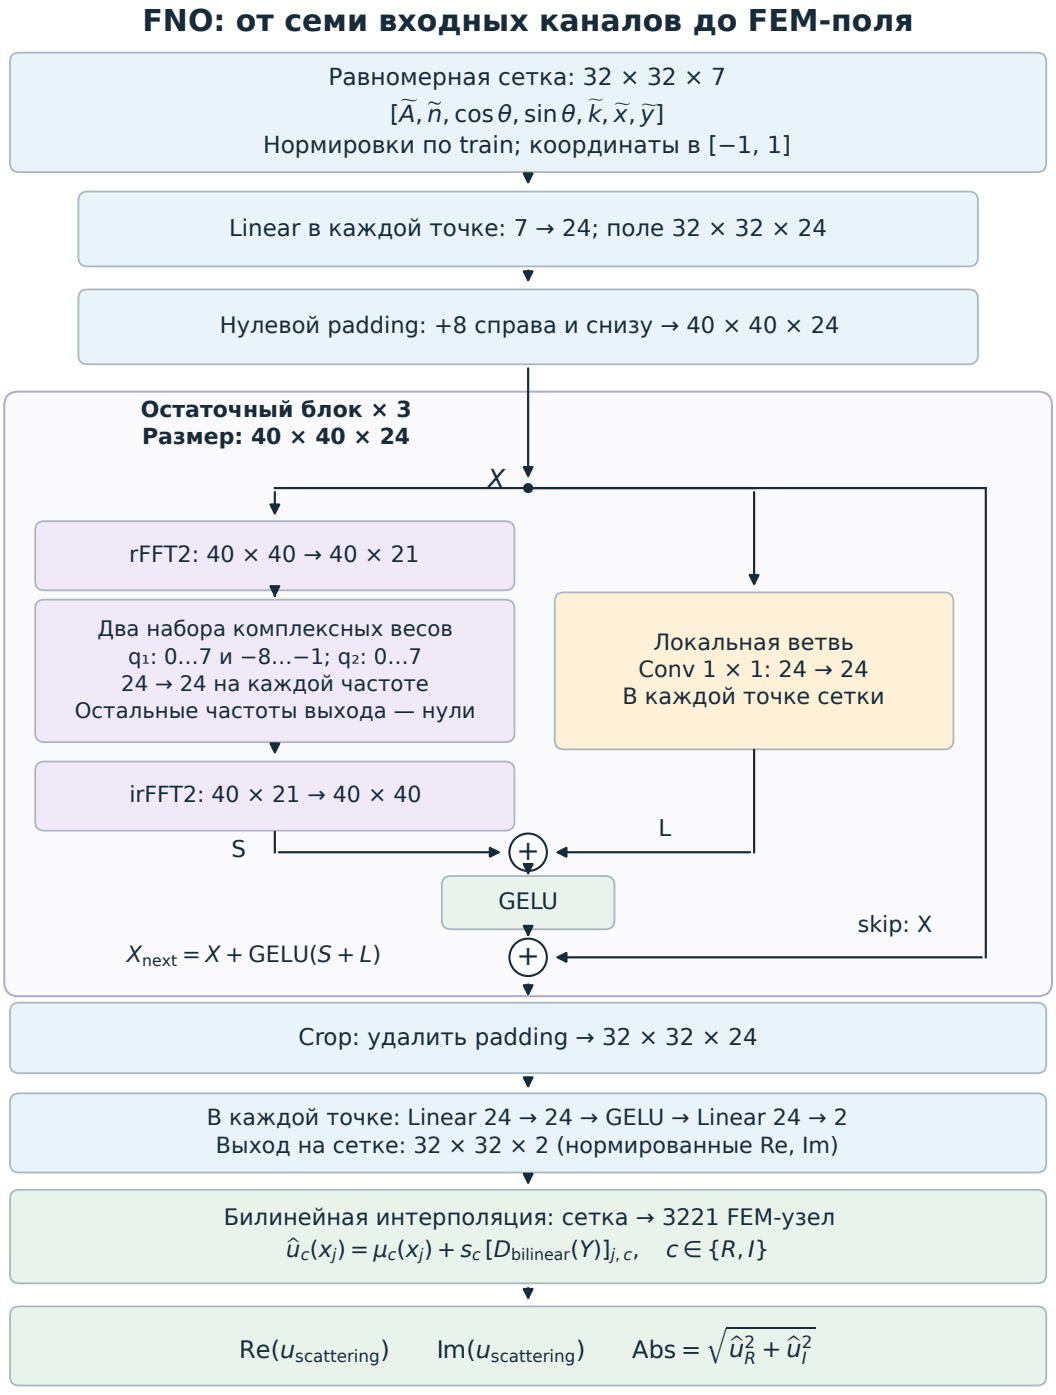


Рис. 4: Текущая архитектура FNO для статических наборов: семь входных каналов, три остаточных блока и восстановление рассеянного поля в FEM-узлах. S — спектральная ветвь с обучаемыми комплексными весами, L — локальная свёртка 1×1; прямая связь переносит вход X блока. $\mu_c(x_j)$ — среднее поле в узле, s_c — общий масштаб компоненты, оба определяются по обучающей выборке. Размеры показаны без оси пакета, каналы указаны последними. Модуль вычисляется из восстановленных Re и Im.

5. ФУНКЦИЯ ПОТЕРЬ И МЕТРИКИ ОШИБКИ

Введём остаток проекции $\boldsymbol{\rho}^{(s)} = \boldsymbol{u}^{(s)} - \boldsymbol{u}_R^{(s)}$. Ортонормированность выходных базисов в евклидовом скалярном произведении даёт тождество

$$\|\widehat{\boldsymbol{u}}^{(s)} - \boldsymbol{u}^{(s)}\|_2^2 = \|\widehat{\boldsymbol{c}}_{\mathrm{re}}^{(s)} - \boldsymbol{c}_{\mathrm{re}}^{(s)}\|_2^2 + \|\widehat{\boldsymbol{c}}_{\mathrm{im}}^{(s)} - \boldsymbol{c}_{\mathrm{im}}^{(s)}\|_2^2 + \|\boldsymbol{\rho}^{(s)}\|_2^2. \tag{21}$$

Оно справедливо для любого предсказания, восстановленного в тех же аффинных пространствах. Поэтому ошибка проекции является нижней границей узловой ошибки такой модели для каждого примера. В вычислениях тождество выполняется с точностью ортогонализации базисов.

Пусть D_{re} и D_{im} — диагональные матрицы масштабов из (13). Используемая функция потерь записывается явно:

$$\mathcal{L}(\boldsymbol{\eta}) = \frac{1}{N_{\mathrm{tr}}} \sum_{s \in \mathcal{I}_{\mathrm{tr}}} \left[\frac{\displaystyle\sum_{q \in \{\mathrm{re},\mathrm{im}\}} \|D_q(\widehat{\widetilde{\boldsymbol{c}}}_q^{(s)} - \widetilde{\boldsymbol{c}}_q^{(s)})\|_2^2 + \|\boldsymbol{\rho}^{(s)}\|_2^2}{\|\boldsymbol{u}^{(s)}\|_2^2} \right]^{1/2}, \tag{22}$$

где $\boldsymbol{\eta}$ — параметры сети. Благодаря (21) это средняя относительная узловая ошибка поля. Возврат масштабов D_q сохраняет физический вклад мод; равные веса нормированных коэффициентов задавали бы другую метрику. Остаток проекции в (22) учитывается внутри квадратного корня.

Для оценки на отложенных данных используются

$$e_{\mathrm{node}}^{(s)} = \frac{\|\widehat{\boldsymbol{u}}^{(s)} - \boldsymbol{u}^{(s)}\|_2}{\|\boldsymbol{u}^{(s)}\|_2}, \qquad e_{L^2}^{(s)} = \left(\frac{(\widehat{\boldsymbol{u}}^{(s)} - \boldsymbol{u}^{(s)})^* M (\widehat{\boldsymbol{u}}^{(s)} - \boldsymbol{u}^{(s)})}{(\boldsymbol{u}^{(s)})^* M \boldsymbol{u}^{(s)}} \right)^{1/2}. \tag{23}$$

Здесь * означает эрмитово сопряжение, а M — согласованная матрица масс для невзвешенной нормы $L^2(\Omega)$, отличная от $M(n)$ в (6). На треугольнике T её локальный блок равен

$$M_T = \frac{|T|}{12} \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}.$$

Эта формула точно интегрирует квадрат модуля кусочно-линейного поля на дискретной сетке. На неравномерной сетке узловая и интегральная нормы различаются. Евклидова SVD-проекция не обязана минимизировать ошибку в норме с матрицей M, поэтому вычисленная для неё ошибка L^2 служит диагностикой сжатия, а не доказанной нижней границей для этой нормы.

6. ОРГАНИЗАЦИЯ ЭКСПЕРИМЕНТА

Сформированы 1000 независимых реализаций среды. Для каждой выбирается угловой сдвиг θ_0, равномерно распределённый на $[0, \pi/4)$, и восемь направлений

$$\theta_j = \theta_0 + \frac{2\pi j}{8}, \qquad j = 0, \ldots, 7.$$

Всего получено 8000 комплексных полей. Случайное разбиение выполняется по идентификаторам сред: все восемь направлений одной среды относятся к одной части выборки (табл. 2). Тем самым обучение и оценка не используют разные направления одной и той же реализации

Таблица 2: Разбиение данных и назначение выборок

Выборка	Среды	Поля	Назначение
Обучающая	800	6400	Базисы, нормировки, веса сети
Валидационная	100	800	Выбор ранга и состояния сети
Тестовая	100	800	Оценка зафиксированной модели

материала в разных частях выборки. Одновременно со средой удерживается и связанное с ней значение k; оценка характеризует новые совместные реализации в диапазонах (4).

Сеть обучается методом Adam с размером пакета 256. Перед обновлением градиент ограничивается по глобальной норме значением 1. Начальный шаг 10^{-3} уменьшается вдвое после каждых 100 эпох с нижним ограничением 10^{-5}. В пределах 500 эпох это ограничение ещё не достигается: на последнем участке используется $6{,}25 \cdot 10^{-5}$. Для инициализации сети и перемешивания пакетов используется seed 42; seed генерации данных и разбиения равен 2026.

После каждой эпохи вычисляется валидационная ошибка. Для итоговой оценки выбирается состояние с наименьшим её значением. Отдельный критерий ранней остановки отслеживает отсутствие улучшения более чем на 10^{-4} на протяжении 80 эпох; проверка остановки начинается после 100 эпох. Предельная длительность запуска равна 500 эпохам. В рассматриваемом запуске достигнут этот предел, критерий ранней остановки не сработал, а лучшая валидационная ошибка получена на эпохе 500.

Числа в следующем разделе приведены по сохранённым результатам вычислительного эксперимента на базе DOLFINx и JAX. Они относятся к полному SVD и одному запуску обучения; оценка разброса по нескольким инициализациям не выполнялась.

7. РЕЗУЛЬТАТЫ И ИХ ОБСУЖДЕНИЕ

Минимальная средняя валидационная узловая ошибка составила 7,0973% на 500-й эпохе. Среднее обучающее значение функции потерь на этой эпохе равно приблизительно 6,6975%. Обучающее значение усредняется по пакетам в процессе обновления параметров, а валидационное вычисляется для фиксированного состояния сети в конце эпохи; они не являются двумя оценками одного и того же состояния во время обучения.

Рисунок 5 показывает замедление уменьшения ошибки после начального этапа. Продолжающееся улучшение к концу интервала и остановка по лимиту эпох не позволяют утверждать достижение сходимости.

Тестовые характеристики выбранного состояния приведены в табл. 3. Для сравнения на тех же полях вычислена проекция (11), использующая истинные коэффициенты решения. Такая проекция не является самостоятельным предсказателем для новой задачи, поскольку требует знания искомого поля.

Таблица 3: Исторический JAX-эксперимент: относительные ошибки на 800 тестовых полях, %; $R = 71$ для каждой части решения

Приближение	Норма	Средняя	Медиана	95-й проц.	Максимум
SVD-проекция	Узловая	0,9221	0,7498	2,2828	3,5029
SVD-SNO	Узловая	6,8833	6,2593	13,3105	20,6574
SVD-проекция	L^2, матрица M	0,6961	0,5726	1,6452	2,6688
SVD-SNO	L^2, матрица M	6,4549	5,9376	12,2804	19,3278

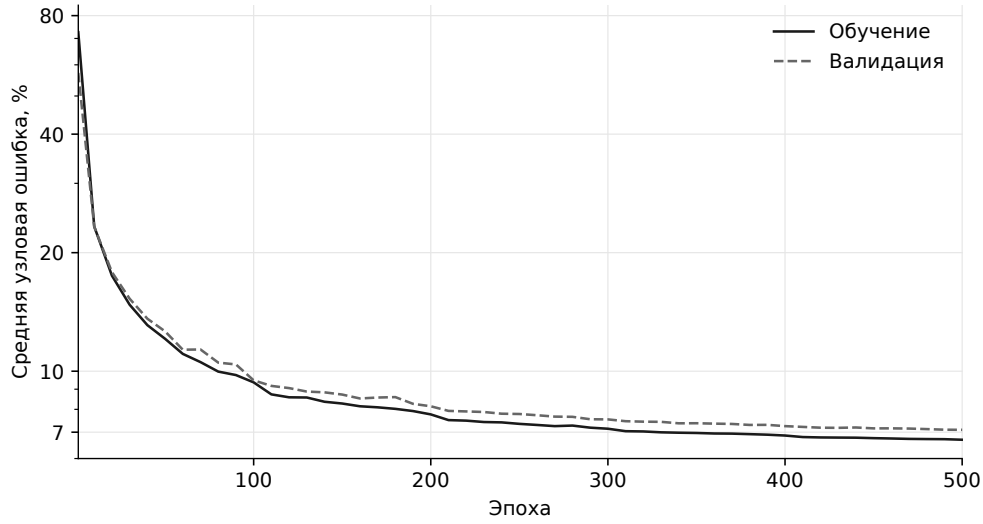


Рис. 5: Средняя относительная узловая ошибка при обучении с полным SVD. Показаны записанные в журнале значения на первой и каждой десятой эпохе, соединённые отрезками; вертикальная шкала логарифмическая.

Средняя узловая ошибка сети примерно в 7,46 раза превышает среднюю ошибку проекции. При фиксированных выходных пространствах разложение (21) связывает дополнительную ошибку с предсказанием коэффициентов. Это указывает на необходимость исследовать обучение отображения при уже достаточно точном пространственном представлении. Разность или отношение средних ошибок не является аддитивным разложением ошибки; тождество (21) относится к квадратам норм каждого отдельного примера.

Средняя тестовая ошибка ниже валидационной; при одном разбиении это различие выборок не доказывает улучшения качества на новых данных. Направления одной среды зависимы: 800 тестовых полей соответствуют 100 отложенным средам. Доверительные интервалы по средам и разброс по повторным запускам не оценивались.

Отдельная диагностика рандомизированного SVD [3] с 136 вычисляемыми модами, 10 дополнительными векторами и двумя степенными итерациями также дала $R = 71$ и среднюю валидационную ошибку проекции 0,9696%. Близость ошибок представления не устанавливает одинаковую точность обучения двух сетей или ускорение полного вычислительного процесса.

Ошибки вычислены относительно дискретного решения (5); сеточная и граничная погрешности отдельно не оценены. Перенос на другие положения включений, сетки и волновые числа вне (4) не проверялся. Оценка ускорения требует измерения полного пути предсказания при заданной точности с отдельным учётом формирования данных, базисов и обучения.

7.1. Статическая среда: сопоставление FEM, SVD-SNO и FNO

Для наглядного показа Re, Im и Abs использованы сохранённые модели SVD-SNO для *одной фиксированной среды* в диапазонах $k \in [1, 2]$ и $k \in [4, 8]$. В каждом диапазоне сформированы 1000 значений частоты и по восемь направлений падающей волны на каждую частоту, то есть 8000 полей; набор углов задаётся отдельно для каждой частоты; сетка содержит 3221 узел и 6280 треугольников. Для каждого диапазона обучена отдельная PyTorch-модель с рандомизированным POD. Эти статические расчёты представляют другой эксперимент, чем исторический JAX-запуск табл. 3, и не заменяют его результаты.

Разбиение здесь выполняется по частотам: все восемь направлений для одного значения k остаются в одной части выборки. Обучающая, валидационная и тестовая части содержат соответственно 670/170/160 частотных групп, то есть 5360/1360/1280 полей. Поэтому тест характеризует предсказание на удержанных частотах той же среды. Он не оценивает перенос на новые материалы, в отличие от разбиения по средам в основном эксперименте.

Поскольку A и n одинаковы во всех примерах статического набора, их центрированные матрицы снимков нулевые и оба входных POD-ранга равны нулю. Вход SVD-SNO состоит из трёх признаков: $\cos\theta$, $\sin\theta$ и нормированного k. Обе SVD-SNO имеют ширину 24 и три остаточных блока, обучены 200 эпох; лучшие валидационные состояния выбраны на эпохах 170 и 198. Для низкого диапазона дополнительно обучена FNO с архитектурой рис. 4. Её обучение остановлено после 142 эпох без улучшения валидационной ошибки в течение 50 эпох, лучшее состояние получено на эпохе 92.

Общий протокол задаёт Adam, начальный шаг 0,002, пакет 32, seed 42, предел 200 эпох и выбор состояния только по валидационной FEM-ошибке. Ширина 24 и глубина 3 у SVD-SNO и FNO не означают одинаковую ёмкость: число параметров приведено в табл. 4. Комплексный вес FNO учитывается как два вещественных параметра. Сохранённые SVD-SNO обучены на CPU, новая FNO — на Apple M4 через MPS; время обучения на этом оборудовании не используется для ранжирования моделей. Ниже сравнивается точность конкретных запусков на общих тестовых FEM-полях.

Таблица 4: Статическая среда, удержанные частоты: относительные ошибки в комплексной FEM-норме L^2, %; число вещественных обучаемых параметров

Диапазон k	Модель	Ранги Re/Im	Парам.	Средняя	Медиана	95-й проц.
$[1, 2]$	SVD-SNO	10/10	3 110	0,9614	0,8824	1,6792
$[1, 2]$	FNO	—	445 010	1,6599	1,6329	1,9505
$[4, 8]$	SVD-SNO	48/48	13 370	5,5375	5,0683	9,0357

На рис. 6–8 показаны примеры, типичные по значению комплексной FEM-ошибки L^2. В каждом диапазоне из всех 1280 тестовых полей выбирается поле с ошибкой, ближайшей к медиане ошибок SVD-SNO этого набора. При равных расстояниях берётся первая позиция сохранённого тестового списка. Для низкого диапазона выбран индекс 2211, $k = 1{,}27628$, $\theta = 2{,}78201$ рад; для высокого — индекс 6077, $k = 7{,}03904$, $\theta = 4{,}24536$ рад. Этот критерий иллюстрирует типичный уровень выбранной метрики, а разброс по тесту характеризуется табл. 4.

В строках рисунков приведены Re, Im и Abs; в столбцах — FEM, предсказание SVD-SNO и абсолютная ошибка выбранной компоненты. Для низкого диапазона обе модели показаны на одном поле, выбранном по SVD-SNO, с общей цветовой шкалой FEM и обоих предсказаний каждой компоненты и общей шкалой ошибок. Таким образом, FNO не получает отдельный отобранный пример. Третья строка ошибок показывает $\big||\widehat{u}_s| - |u_s|\big|$, а не $|\widehat{u}_s - u_s|$. Ошибка отдельного примера и средняя ошибка набора являются разными характеристиками.

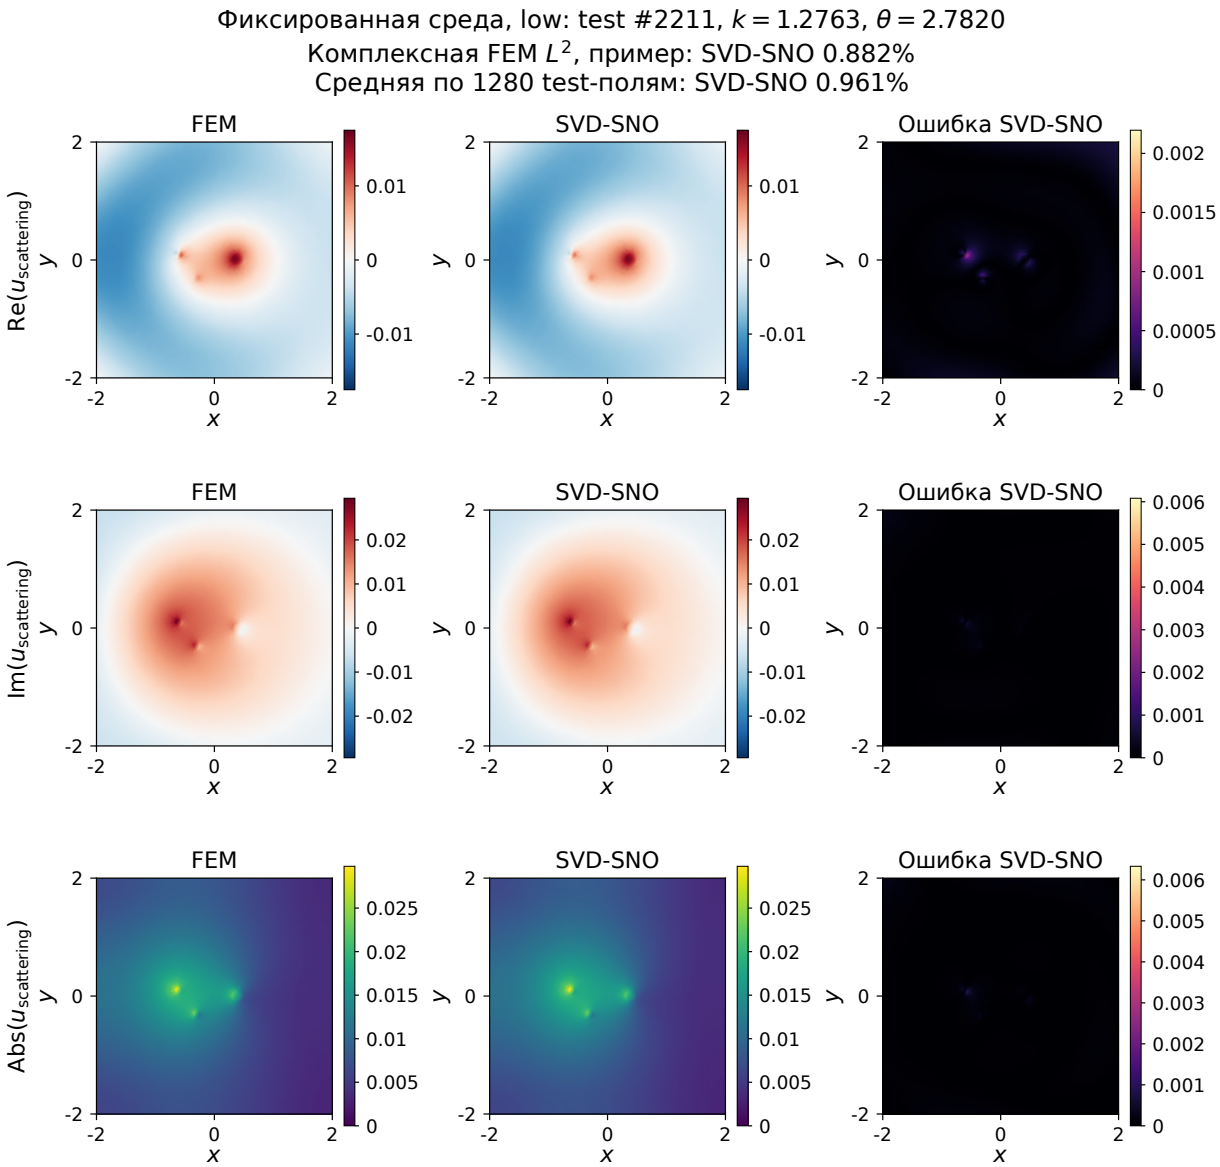


Рис. 6: Статическая среда, $k \in [1, 2]$: FEM и randomized SVD-SNO для примера, ближайшего к медиане тестовых ошибок, $k = 1{,}27628$. Строки: Re, Im и Abs; столбцы: FEM, предсказание и абсолютная ошибка компоненты. Относительная комплексная FEM-ошибка L^2 примера равна 0,8825%, средняя на всём тестовом наборе — 0,9614%. С FNO на рис. 7 согласованы поле и цветовые шкалы.

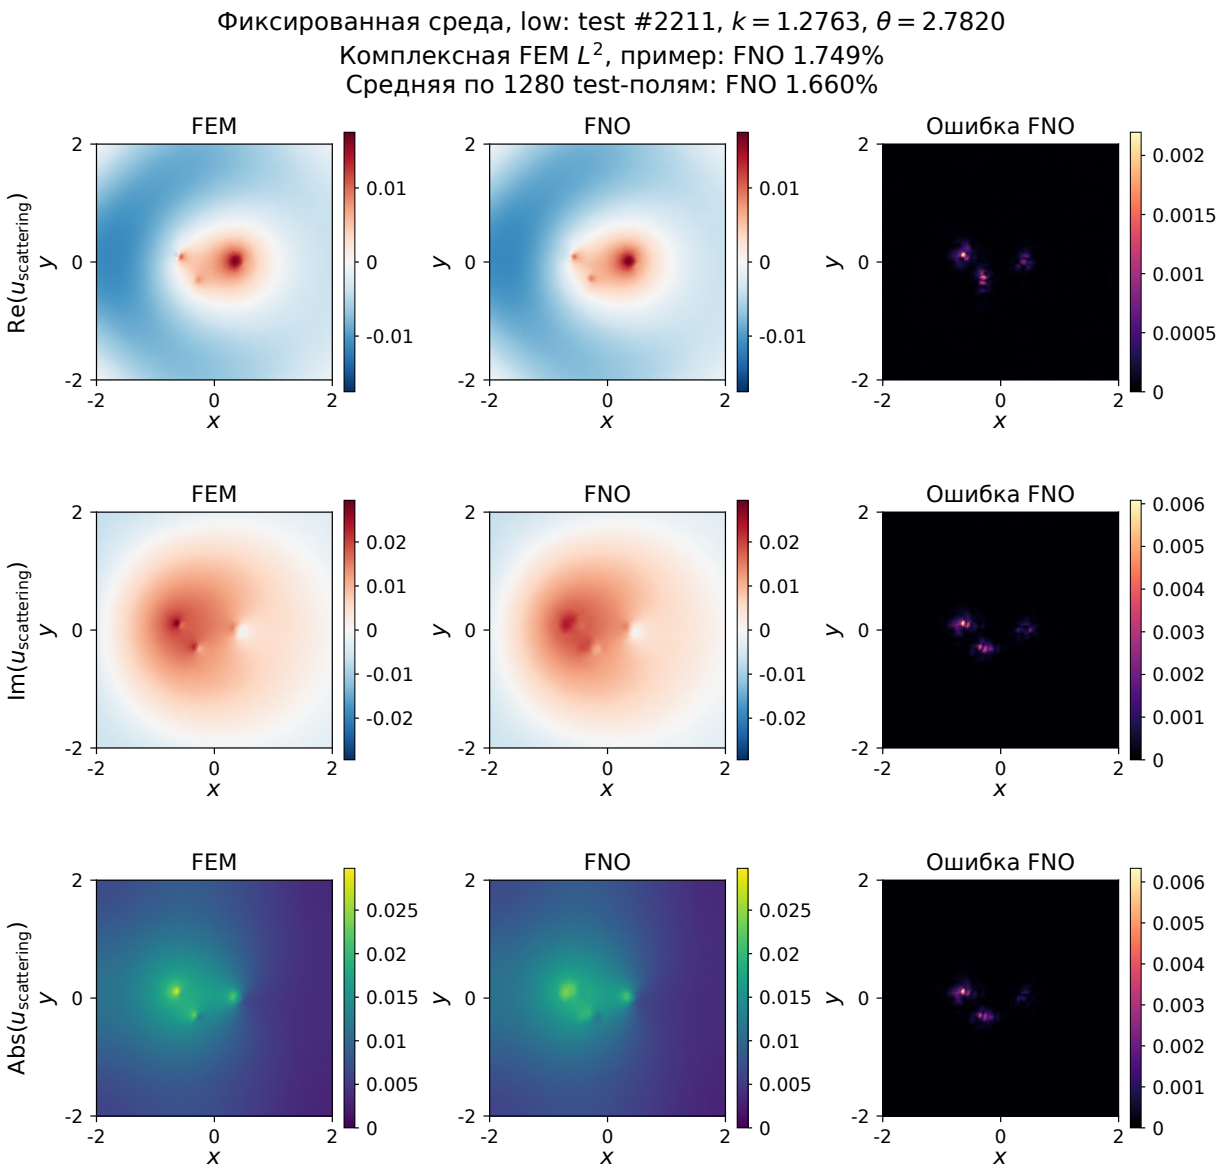


Рис. 7: Статическая среда, $k \in [1, 2]$: FEM и FNO на том же примере 2211, что на рис. 6, $k =$ 1,27628. Строки: Re, Im и Abs; столбцы: FEM, предсказание и абсолютная ошибка компоненты. Комплексная FEM-ошибка примера — 1,7488%, средняя на всём тестовом наборе — 1,6599%. Цветовые шкалы согласованы с SVD-SNO. Пример выбран по медиане ошибок SVD-SNO, а не по ошибке FNO.

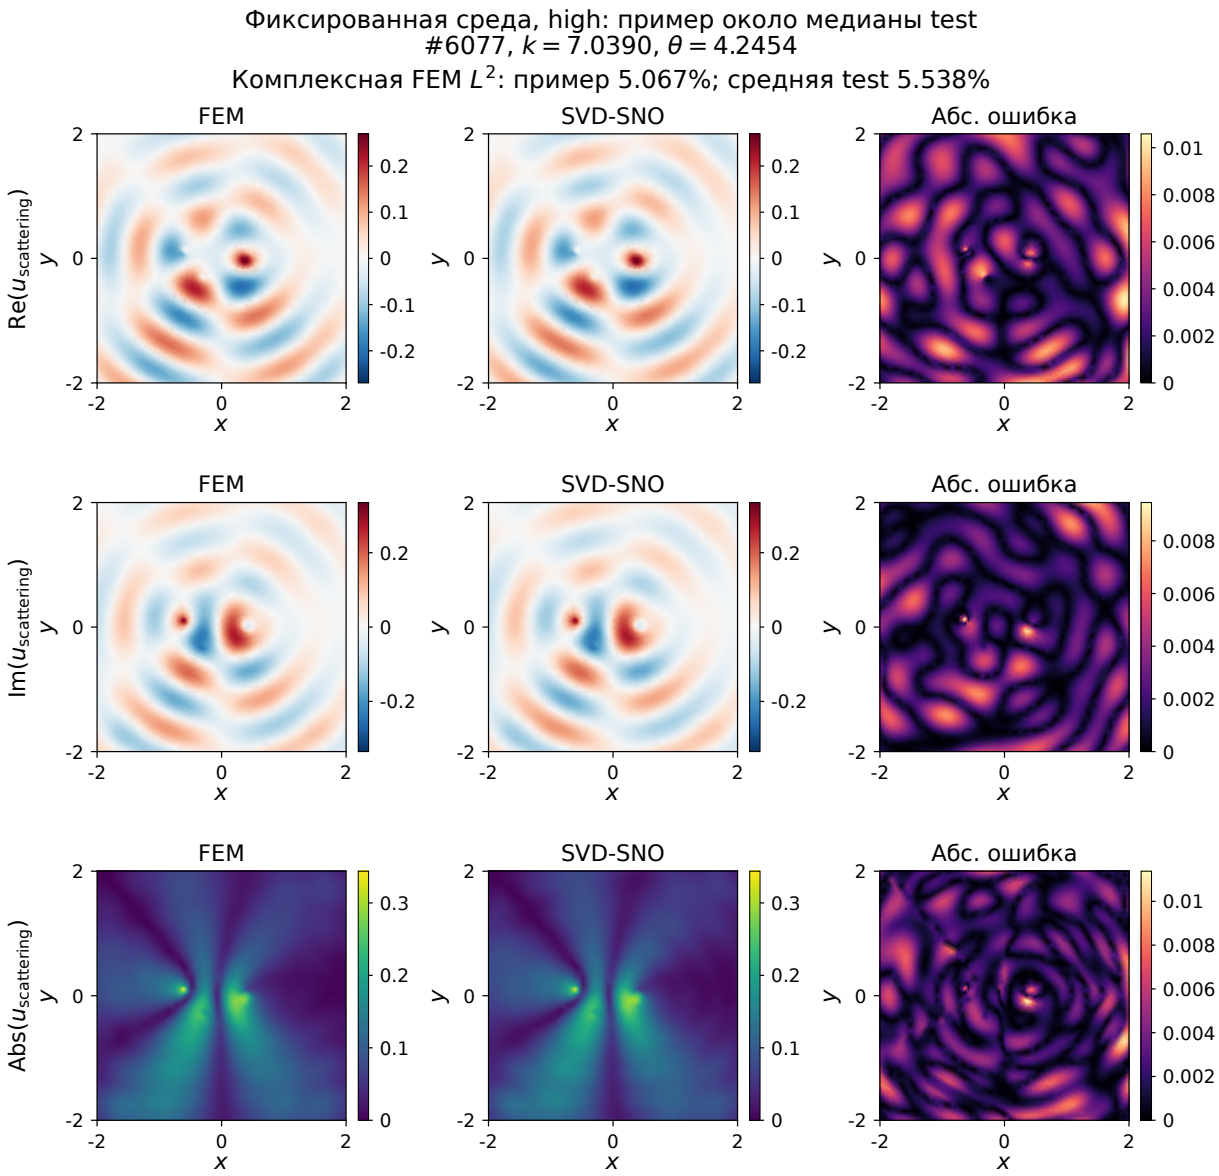


Рис. 8: Статическая среда, $k \in [4, 8]$: FEM, randomized SVD-SNO и абсолютная ошибка компоненты для примера, ближайшего к медиане тестовых ошибок, $k = 7{,}03904$. Строки: Re, Im и Abs. Относительная комплексная FEM-ошибка L^2 примера составляет 5,0670%, средняя на всём тестовом наборе — 5,5375%. Для этого диапазона обучена отдельная модель; переноса низкочастотной модели здесь нет.

8. ЗАКЛЮЧЕНИЕ

Построено приближение решения задачи рассеяния, сочетающее конечно-элементные данные, POD и нейросетевое отображение коэффициентов. Базисы и нормировки определяются по обучающим средам, ранг и состояние сети — по валидационным. Оценка выполняется на отложенных средах.

При 71 моде для каждой части поля средняя валидационная узловая ошибка проекции меньше 1%, а средняя тестовая ошибка сети в норме L^2 равна 6,455%. Различие ошибок проекции и сети указывает на необходимость улучшения предсказания коэффициентов. Дальнейшие задачи — повторные запуски, сравнение рангов, проверка сеточной сходимости и измерение вычислительной стоимости.

В отдельном эксперименте с фиксированной средой средние тестовые FEM-ошибки randomized SVD-SNO составляют 0,9614% для $k \in [1, 2]$ и 5,5375% для $k \in [4, 8]$. Эти результаты характеризуют удержанные частоты, дополняют иллюстрации Re, Im и Abs и не являются оценкой переноса на новые среды.

ЛИТЕРАТУРА

1. Li Z., Kovachki N., Azizzadenesheli K., Liu B., Bhattacharya K., Stuart A., Anandkumar A. Fourier Neural Operator for Parametric Partial Differential Equations. 2020. arXiv:2010.08895.
2. Fanaskov V., Oseledets I. Spectral Neural Operators. 2022. arXiv:2205.10573.
3. Halko N., Martinsson P.-G., Tropp J. A. Finding Structure with Randomness: Probabilistic Algorithms for Constructing Approximate Matrix Decompositions. SIAM Review. 2011. Vol. 53, No. 2. P. 217–288. doi:10.1137/090771806.